LLM · VLM · VLA · 레드티밍 · 기준일 2026. 10. 25

LLM의 역사와 작동 원리, 그리고 레드티밍

임베딩에서 VLA와 의료 LLM 레드팀까지

능력을 끌어내는 기술과 의도한 범위에 묶어 두는 기술이 번갈아 병목이 되어 온 과정

「억제와 레드티밍의 역사」 보고서 확장판 · 그림은 모두 개념도

요약 이 문서의 줄기

언어 모델의 역사는 끌어내기와 묶어 두기가 번갈아 병목이 된 과정이다

임베딩, 어텐션, 대규모 사전학습이 능력을 만들었고 프롬프트 엔지니어링은 그 능력을 끌어내는 기술로 출발했다. 2023년까지 사용자는 "단계별로 생각하라" 같은 문구로 부족한 부분을 메웠지만, 2025~2026년 OpenAI와 Anthropic의 공식 가이드는 독려 문구를 줄이고 범위를 정하라고 권한다. 병목이 **능력 부족에서 능력 과잉으로** 옮겨갔기 때문이다.

0.001%

학습 토큰을 오정보로 바꾼 비율

이것만으로 해로운 출력이 늘었다 (Alber 외, 2025)

영상 속 지시

VLM이 병변을 놓치게 유도

종양학 영상에 숨긴 지시 (Clusmann 외, 2025)

50~82%

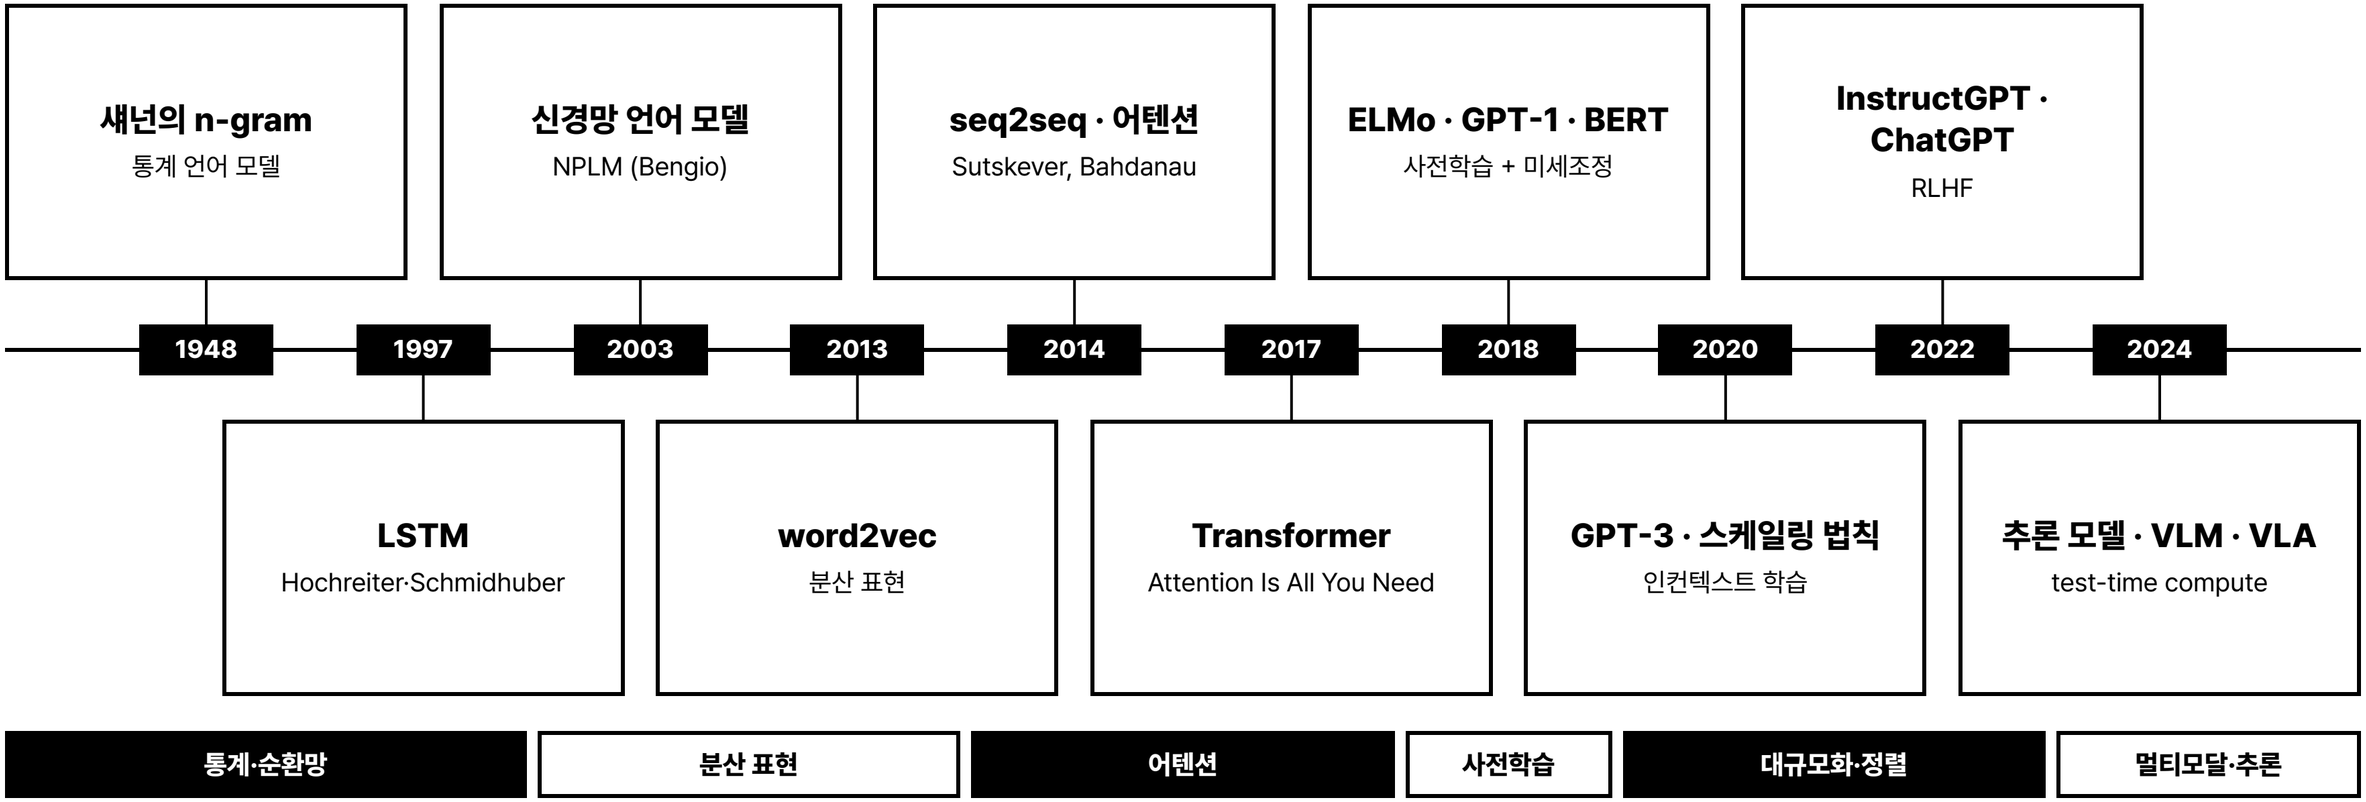
허위 세부정보를 사실처럼 부연한 비율

임상 사례 300개, 6개 모델 (Omar 외, 2025)

레드티밍 레드티밍은 같은 메커니즘을 반대 방향에서 다룬다. 퓨샷 학습은 many-shot 탈옥이, 자동 프롬프트 최적화는 GCG가, 도구 사용은 간접 프롬프트 인젝션이 되었다. "LLM을 오작동시키는 기술"은 결함을 찾아 고치는 절차의 수단 중 하나다.

언어 모델 그림 1 · 언어 모델의 계보

통계 모델에서 멀티모달·추론 모델까지 여섯 시기를 거쳤다



가로축 간격은 사건 순서이며 시간 비례가 아니다. 섀넌 1948과 GPT-1 2018은 원문에서 (미검증)으로 표시된 항목이다.

신경망 언어 모델은 단어마다 연속 벡터를 학습해 차원의 저주를 풀었다

n-gram 모델의 두 가지 한계

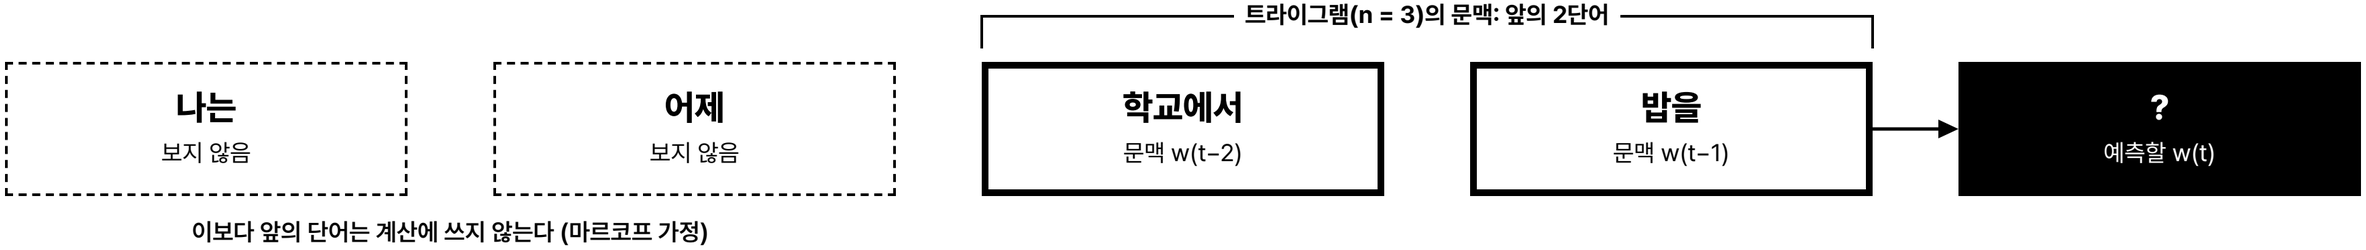
- 앞의 n−1개 단어만 보고 다음 단어 확률을 센다. 섀넌의 1948년 근사가 출발점으로 소개된다 (미검증)
- 학습 데이터에 없던 단어 조합에는 확률을 줄 수 없다
- n을 키우면 가능한 조합이 기하급수적으로 늘어 데이터가 감당하지 못한다 (차원의 저주)

NPLM (Bengio 외, JMLR 2003)

- 단어마다 연속 특징 벡터를 학습한다
- "고양이가 소파에서 잔다"를 배운 모델이 "강아지가 소파에서 잔다"에도 높은 확률을 준다
- 단어 벡터와 다음 단어 예측 함수를 함께 학습하는 틀이 이후 모든 신경망 언어 모델의 기본이 되었다

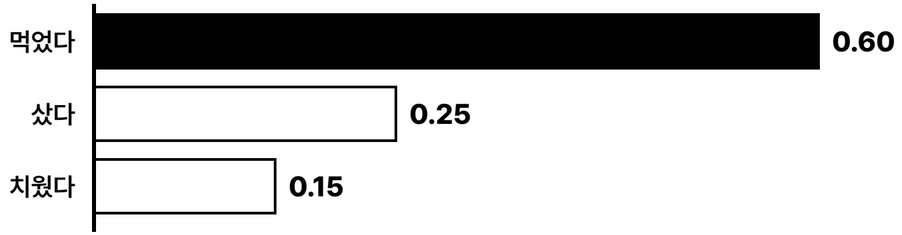
구조	시기	핵심	남은 문제
RNN	2010년대 초중반	단어를 하나씩 읽으며 은닉 상태 갱신	긴 문장에서 기울기 소실
LSTM	Neural Computation 1997	게이트로 정보를 남기거나 지움	순차 계산이라 병렬화가 어려움
seq2seq	arXiv 1409.3215, 2014.09	인코더가 문장 전체를 고정 길이 벡터로 압축	고정 길이 병목

n-gram 모델은 앞의 n−1개 단어만 보고 다음 단어의 확률을 센다



이보다 앞의 단어는 계산에 쓰지 않는다 (마르코프 가정)

말뭉치에서 센 횟수로 확률을 구한다 (예시 값)



P(w(t) | 학교에서, 밥을) = C(학교에서 밥을 w(t)) ÷ C(학교에서 밥을)

C(·)는 학습 말뭉치에서 그 단어열이 나온 횟수다. '학교에서 밥을'이 100번 나왔고 그 뒤에 '먹었다'가 60번 왔다면 확률은 0.60이다.

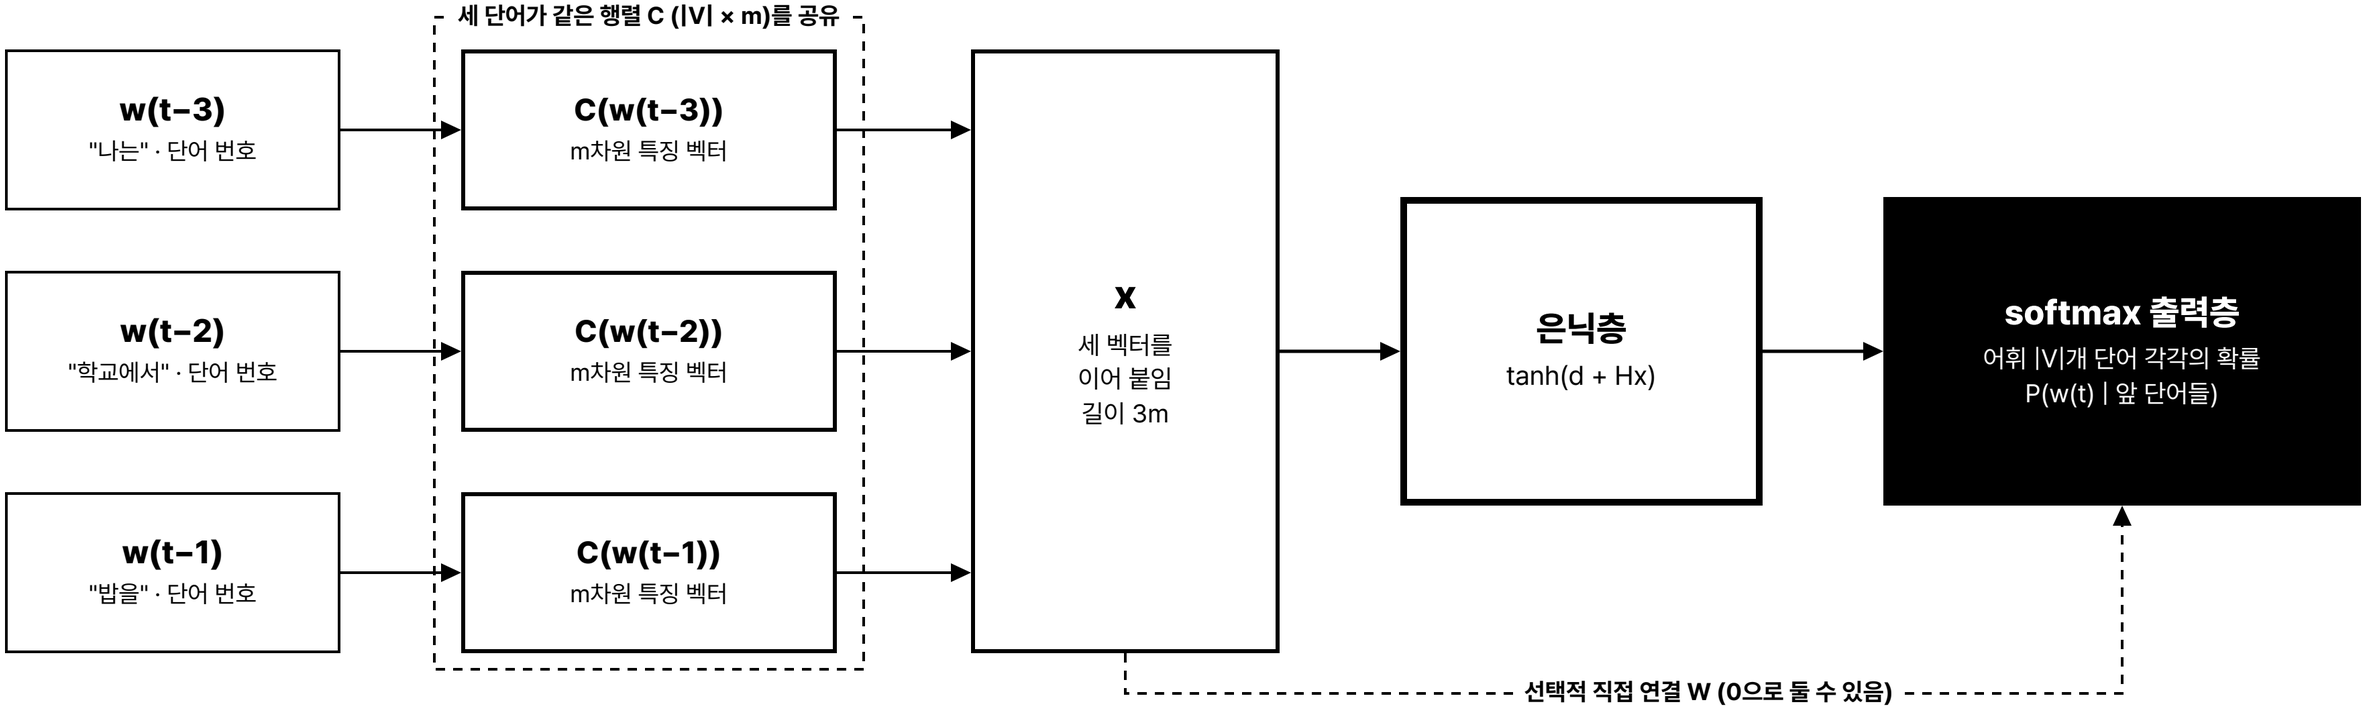
본 적 없는 단어열: 희소성과 스무딩

- 말뭉치에 한 번도 나오지 않은 단어열은 횟수가 0이라 확률도 0이 된다
- 스무딩(smoothing)은 본 적 있는 단어열의 확률을 조금 덜어 본 적 없는 단어열에 나눠 준다

n을 키울 때의 문제

- 문맥을 길게 볼수록 예측은 정확해지지만, 가능한 단어열의 수가 어휘 크기의 n제곱으로 늘어난다
- 늘어난 조합 대부분이 말뭉치에 나오지 않아 데이터가 감당하지 못한다 (차원의 저주)

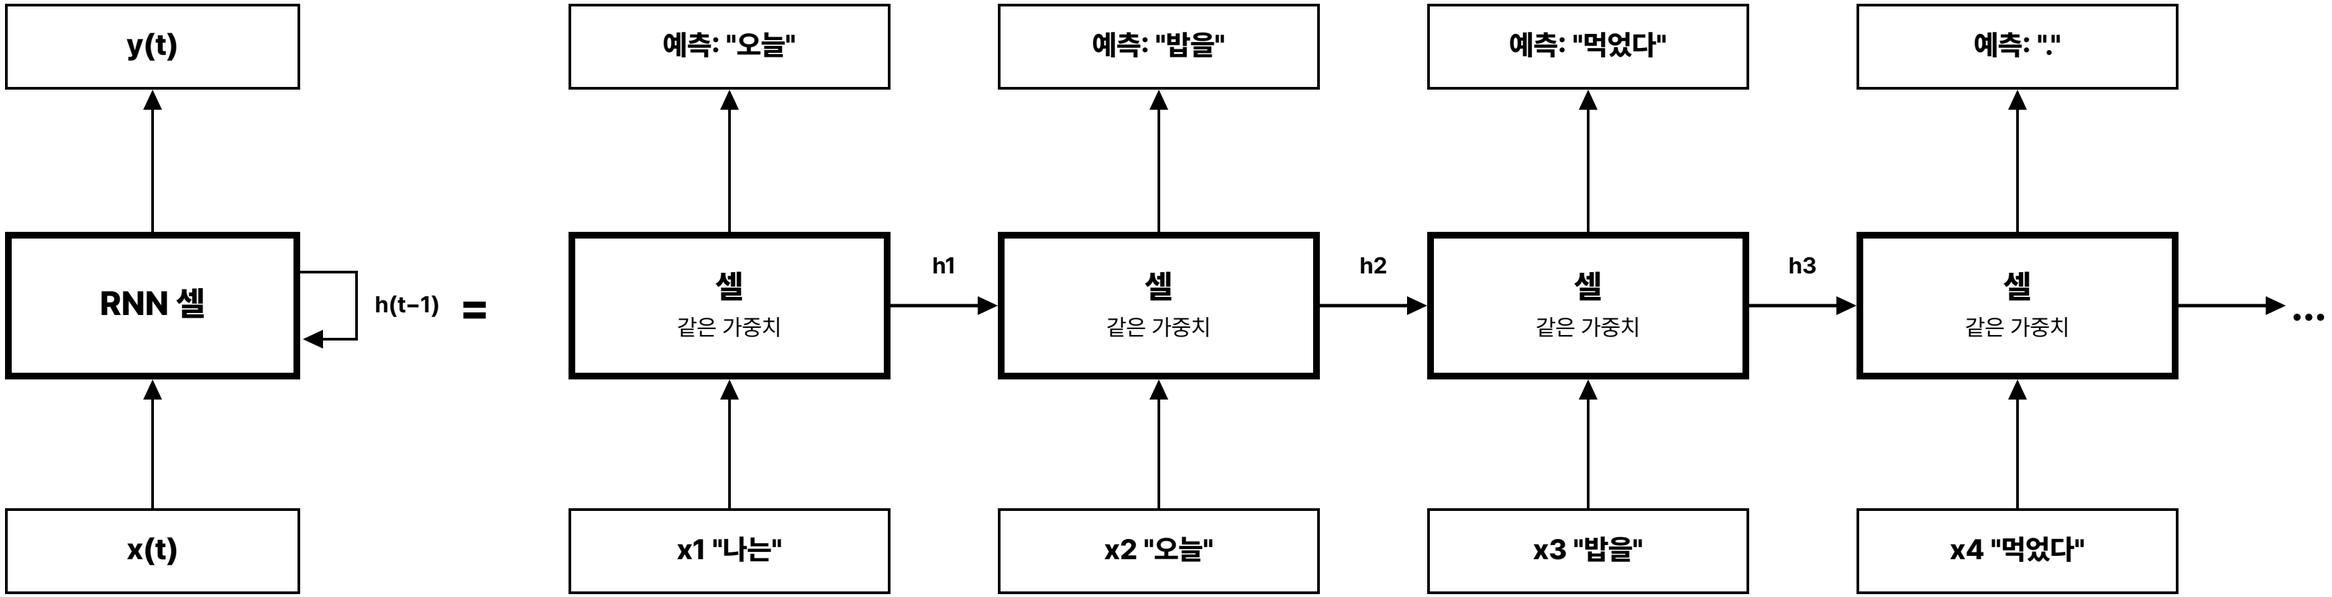
NPLM은 앞 단어들을 벡터로 바꿔 이어 붙이고 신경망으로 다음 단어를 예측한다



$$y = b + Wx + U \cdot \tanh(d + Hx),\ P(w(t) \mid \text{앞 단어들}) = \text{softmax}(y)$$

특징 행렬 C와 신경망 가중치를 함께 학습하므로 비슷한 문맥에 쓰이는 단어는 비슷한 벡터를 갖게 된다. 그림은 앞 3단어를 보는 경우(n = 4)이며 단어는 설명용 예시다.

순환 신경망은 은닉 상태를 다음 시점으로 넘기며 단어를 하나씩 읽는다



$$h(t) = \tanh(W_h \cdot h(t-1) + W_x \cdot x(t) + b)$$
$$y(t) = \mathrm{softmax}(W_y \cdot h(t))$$

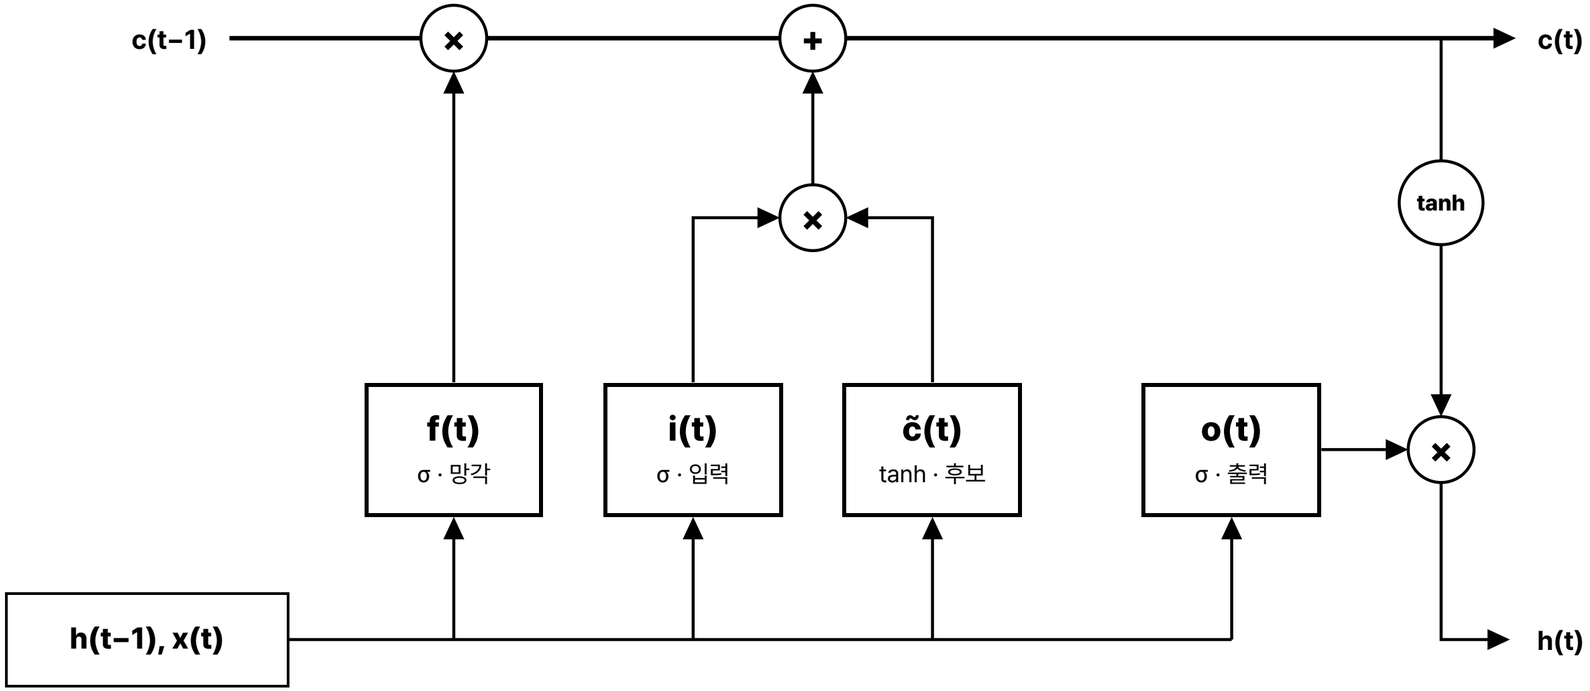
오늘날 흔히 쓰는 표기다. Elman(1990)의 단순 순환망은 직전 시점의 은닉층 값을 문맥 유닛에 복사해 두고 다음 입력과 함께 은닉층에 넣는다.

기울기 소실

- 학습할 때 오차를 시간을 거슬러 전파하는데(BPTT), 시점마다 같은 가중치가 거듭 곱해져 먼 과거로 갈수록 기울기가 0에 가까워진다
- 그래서 멀리 떨어진 단어 사이의 관계를 배우기 어렵다 (Bengio·Simard·Frasconi, 1994)

LSTM은 셀 상태와 세 개의 게이트로 무엇을 남기고 잊을지 정한다

셀 상태 c: 곱하기와 더하기만 거쳐 다음 시점으로 흐르므로 먼 과거의 정보와 기울기가 잘 전달된다



한 시점의 계산

$$f(t) = \sigma(W_f \cdot [h(t-1), x(t)] + b_f)$$

$$i(t) = \sigma(W_i \cdot [h(t-1), x(t)] + b_i)$$

$$\tilde{c}(t) = \tanh(W_c \cdot [h(t-1), x(t)] + b_c)$$

$$c(t) = f(t) \odot c(t-1) + i(t) \odot \tilde{c}(t)$$

$$o(t) = \sigma(W_o \cdot [h(t-1), x(t)] + b_o)$$

$$h(t) = o(t) \odot \tanh(c(t))$$

σ는 0과 1 사이 값을 내므로 각 게이트는 정보를 얼마나 통과시킬지 정하는 밸브처럼 작동한다. ⊙는 원소별 곱이다.

출처 Hochreiter·Schmidhuber(1997)가 셀 상태와 입력·출력 게이트를 제안했고, 망각 게이트는 Gers·Schmidhuber·Cummins(2000)가 더했다. 위 식은 망각 게이트를 포함한 오늘날의 표준형이다.

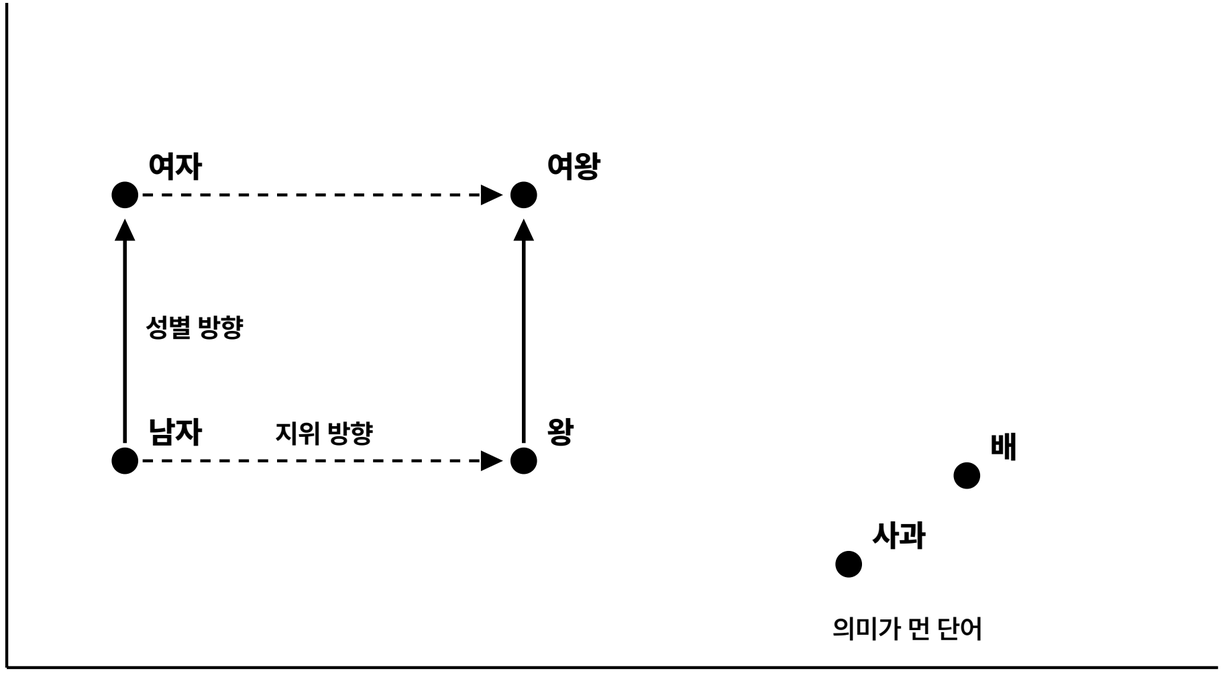
임베딩은 의미 관계를 벡터의 방향과 거리로 나타낸다

원-핫 표현: 모든 단어가 서로 같은 거리

단어	차원1	차원2	차원3	차원4	차원5
왕	1	0	0	0	0
여왕	0	1	0	0	0
남자	0	0	1	0	0
여자	0	0	0	1	0
사과	0	0	0	0	1

어휘가 V개면 V차원 희소 벡터가 된다. 서로 다른 단어의 내적이 항상 0이라 의미 유사성을 담지 못한다.

분산 표현(임베딩): 의미가 방향과 거리로 표현됨



왕 − 남자 + 여자 ≈ 여왕 (Mikolov 외, 2013의 유추 과제). 실제 임베딩은 수백~수천 차원이며 그림은 2차원 투영 예시다.

word2vec은 주변 단어와 가운데 단어를 서로 맞히며 단어 벡터를 배운다

창 크기 2: 가운데 단어의 앞뒤 2단어가 주변 단어

작은	고양이가	소파에서	조용히	잔다
w(t−2)	w(t−1)	w(t) 가운데 단어	w(t+1)	w(t+2)



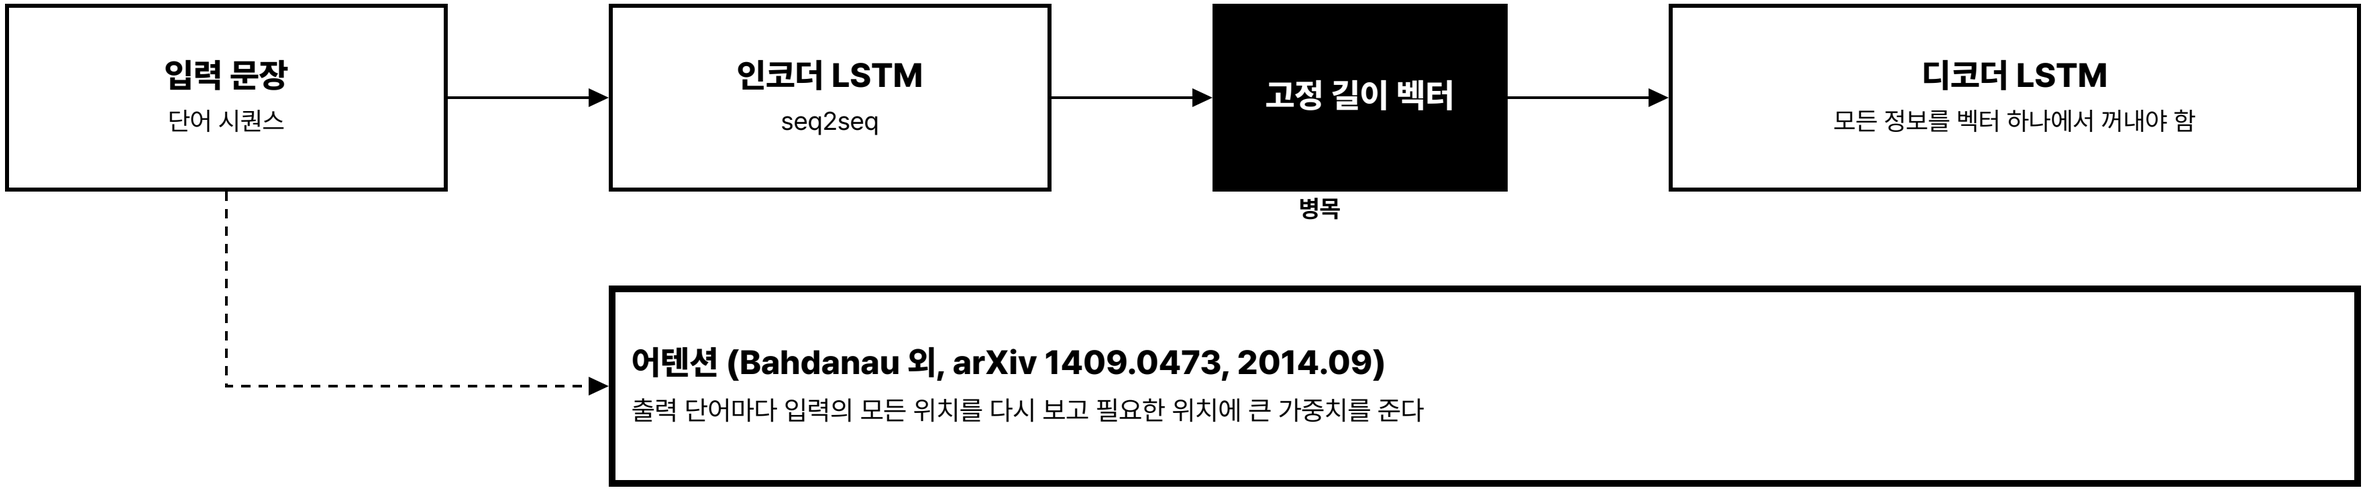
CBOW는 주변 단어 벡터를 평균해 한 번 예측하고, skip-gram은 가운데 단어 하나로 주변 단어를 각각 예측한다. 목적은 예측 자체보다 학습이 끝난 뒤 남는 단어 벡터다. 문장은 설명용 예시다.

정적 임베딩에서 문맥 임베딩으로 넘어가며 같은 단어도 다른 벡터를 갖게 되었다

연구	출처	방식	의미
word2vec (Mikolov 외)	arXiv 1301.3781, 2013.01	CBOW는 주변 단어로 가운데 단어를, skip-gram은 가운데 단어로 주변 단어를 맞힘	"왕 − 남자 + 여자 ≈ 여왕" 같은 유추 관계가 관찰됨
GloVe (Pennington 외)	EMNLP 2014	말뭉치 전체의 단어 동시 출현 통계를 직접 분해	word2vec과 비슷한 성질의 벡터
정적 임베딩의 한계		단어 하나에 벡터 하나	"배를 타다"와 "배가 아프다"의 배가 같은 벡터
문맥 임베딩	ELMo, BERT (2018)	문맥에 따라 벡터가 달라짐	오늘날 LLM 계산과 RAG 벡터 검색의 출발점

레드티밍 관점 임베딩도 공격 대상이다. OWASP LLM Top 10 2025는 "벡터·임베딩 약점"을 새 항목으로 추가했다.

어텐션은 입력을 벡터 하나로 압축할 필요를 없앴다



사람의 번역과 닮은 점

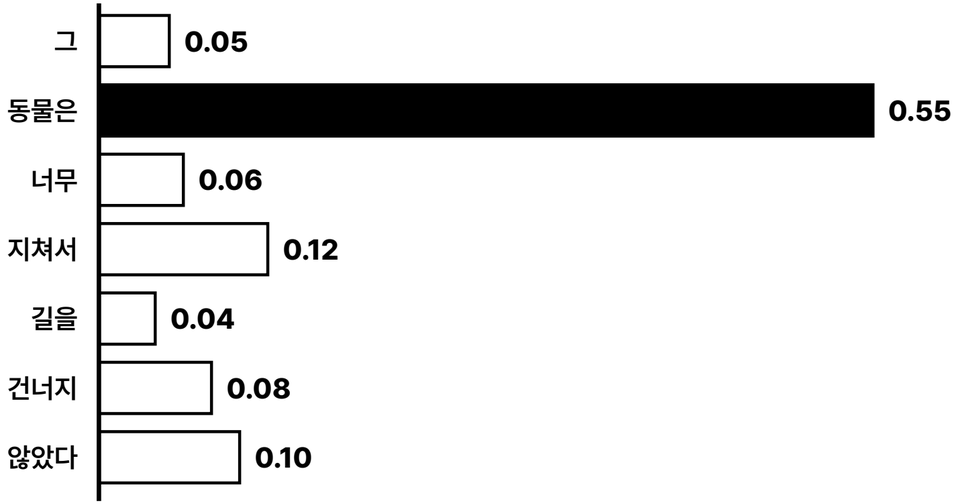
번역할 때 원문의 해당 부분을 다시 보는 것처럼, 디코더가 출력 단어를 만들 때마다 입력의 관련 위치를 참조한다

해석 가능성

어떤 출력 단어가 어떤 입력 단어에 주목했는지를 가중치로 볼 수 있게 되었다

각 토큰은 쿼리로 다른 토큰의 키와 유사도를 구해 값을 가중합한다

'지쳐서'가 주목하는 곳 (가중치 예시 값)



주체인 '동물은'에 가장 큰 가중치를 주어, 누가 지쳤는지에 대한 정보를 '지쳐서'의 새 표현에 담는다.

$$\text{Attention}(Q, K, V) = \text{softmax}(QK^T / \sqrt{d_k}) \cdot V \text{ (Vaswani 외, 2017)}$$

계산 순서

입력 X
토큰 임베딩

↓

Q = XW_Q, K = XW_K, V = XW_V
서로 다른 가중치 행렬

↓

점수 = $QK^T / \sqrt{d_k}$
쿼리와 모든 키의 내적

↓

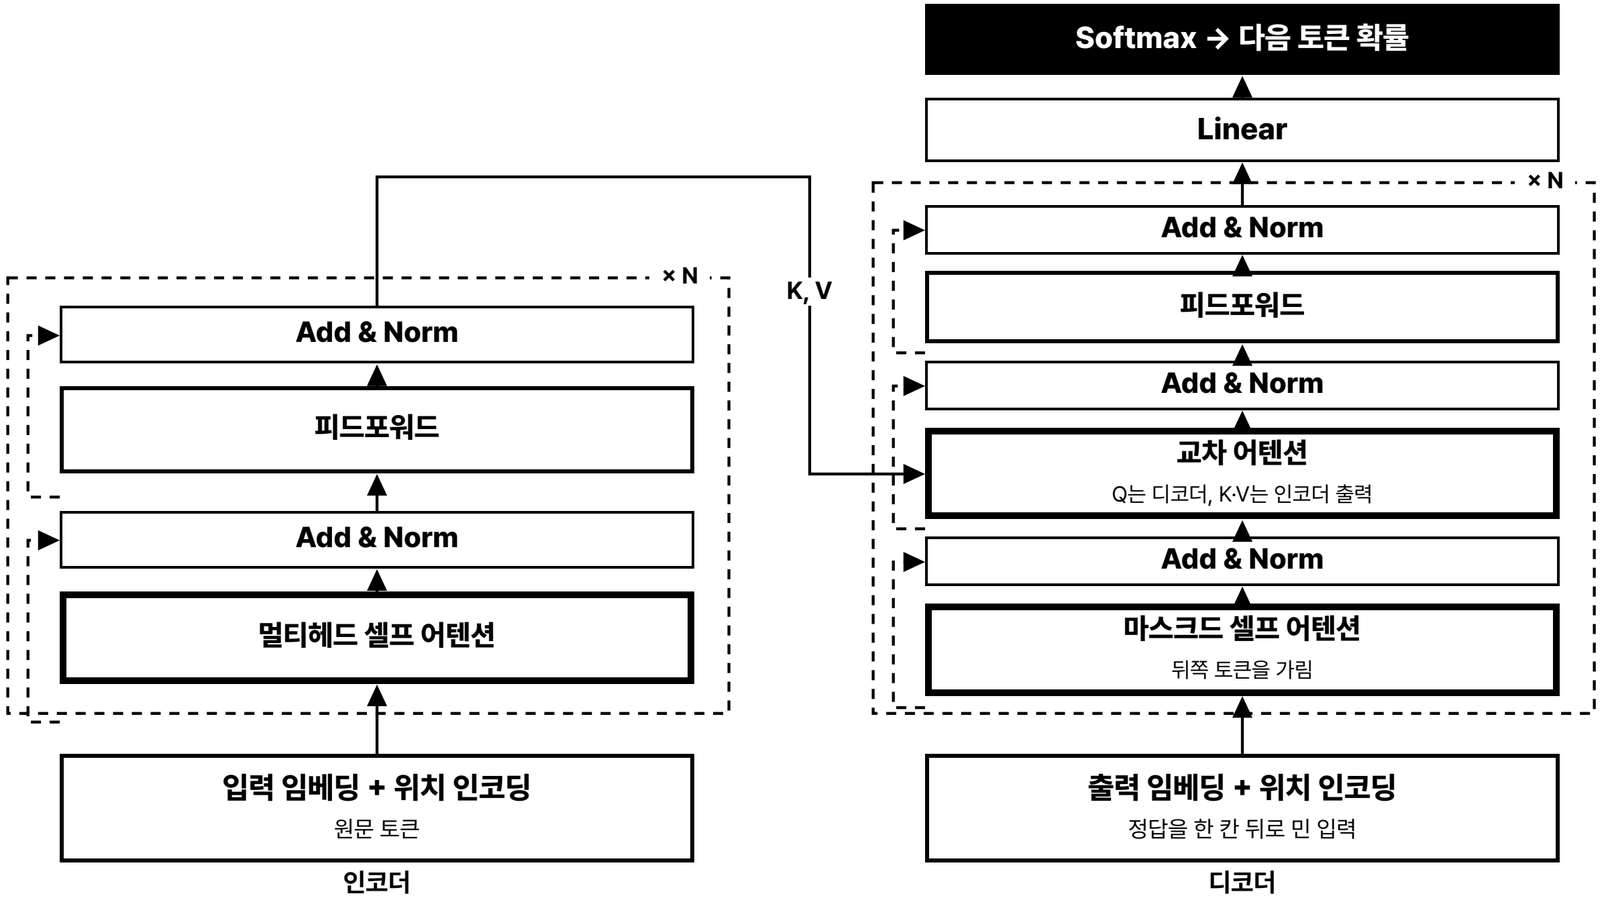
softmax → 가중치
합이 1인 분포

↓

가중치 · V = 출력
문맥이 반영된 새 표현

멀티헤드 어텐션은 이 계산을 h개 헤드에서 병렬로 수행해 문법·지시·의미 관계를 동시에 포착한다. 순환이 없어 모든 토큰을 한 번에 병렬 처리할 수 있다.

트랜스포머는 어텐션과 피드포워드 층을 잔차 연결과 정규화로 감싸 N번 쌓는다



논문의 기본 모델

- 인코더와 디코더 각각 N = 6층
- 모델 차원 512, 어텐션 헤드 8개, 피드포워드 차원 2,048
- 각 부분층은 LayerNorm(x + Sublayer(x))로 감싼다. 점선이 잔차 연결이다
- 위치 정보는 사인·코사인 함수로 만든 위치 인코딩을 더해 넣는다

세 갈래와의 관계 (다음 장 그림 4)

- BERT는 왼쪽 인코더만 쌓는다
- GPT 계열은 교차 어텐션을 뺀 디코더만 쌓는다
- 마스크드 셀프 어텐션은 아직 생성하지 않은 뒤쪽 토큰을 보지 못하게 한다

같은 트랜스포머 블록이 마스크와 목표에 따라 세 갈래로 나뉘었다

인코더 전용 BERT (2018)



어텐션 마스크

양방향 어텐션

모든 토큰이 앞뒤를 함께 봄

사전학습 목표

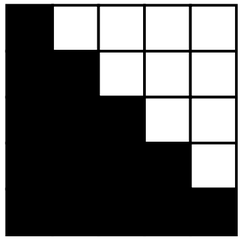
마스크 언어 모델(MLM)

'나는 [MASK]를 먹었다' → 밥

주 용도

분류, 개체명 인식, 검색 임베딩

디코더 전용 GPT 계열 (2018~)



어텐션 마스크

인과(causal) 어텐션

앞쪽 토큰만 볼 수 있음

사전학습 목표

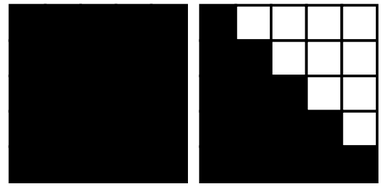
다음 토큰 예측

'나는 밥을' → 먹었다

주 용도

생성, 대화, 오늘날 LLM의 주류

인코더-디코더 T5 (2019)



어텐션 마스크

인코더 양방향

디코더 인과 +

교차 어텐션

사전학습 목표

텍스트→텍스트 변환

'translate: ...' → 번역문

주 용도

번역, 요약. 모든 과제를 텍스트 생성으로 통일

BERT는 입력 WordPiece 토큰의 15%를 가려 맞히는 MLM과 다음 문장 예측(NSP)으로 사전학습했다. BERT-base 1억 1천만, BERT-large 3억 4천만 파라미터. T5의 과제 접두어는 프롬프트의 직접적인 전신이다.

능력이 커지자 사용자 의도에 맞추는 정렬이 다음 과제가 되었다

연구	출처	보고한 내용
스케일링 법칙 (Kaplan 외)	arXiv 2001.08361, 2020.01	손실이 파라미터 수, 데이터 양, 연산량에 대해 거듭제곱 법칙으로 줄어든다
GPT-3	arXiv 2005.14165, 2020	1,750억 파라미터에서 미세조정 없이 프롬프트 속 예시만으로 새 과제를 수행 (인컨텍스트 학습)
Chinchilla (Hoffmann 외)	arXiv 2203.15556, 2022.03	같은 연산 예산에서는 모델 크기와 학습 토큰 수를 같은 비율로 늘리는 것이 최적
InstructGPT (Ouyang 외)	arXiv 2203.02155, 2022.03	시연과 선호 비교로 미세조정하는 RLHF. 평가자들이 13억 InstructGPT를 1,750억 GPT-3보다 선호
ChatGPT	2022.11 공개	RLHF를 대화형으로 다듬어 LLM이 연구실 밖으로 나왔다

전환점 여기서부터 프롬프트 엔지니어링과 레드티밍이 본격적으로 시작된다.

프롬프트 기법은 호출 횟수와 외부 자원 사용에 따라 여섯 층으로 정리된다



아래층은 한 번의 호출 안에서 입력을 설계하는 기법이고, 위로 갈수록 호출 수와 자율성이 늘어 여러 번의 호출, 외부 도구, 상태 관리가 필요하다. 다음 장부터 주요 기법을 한 장씩 다룬다.

강의에서 다루는 열여덟 가지 방법론과 원본 논문

묶음	방법론	원본 논문
입력 설계	Zero-shot · Few-shot · 역할 부여 · 구조화(구분자·XML·출력 형식)	Brown 외 2020 (arXiv 2005.14165) · Reynolds·McDonell 2021 (2102.07350) · Kong 외 NAACL 2024 (2308.07702) · OpenAI·Anthropic 공식 가이드
추론 유도	Chain-of-Thought · Zero-shot CoT · Plan-and-Solve · Least-to-Most	Wei 외 2022 (2201.11903) · Kojima 외 2022 (2205.11916) · Wang 외 ACL 2023 (2305.04091) · Zhou 외 2022 (2205.10625)
질문 분해·지식	Self-Ask · Step-Back · Generated Knowledge	Press 외 2022 (2210.03350) · Zheng 외 ICLR 2024 (2310.06117) · Liu 외 ACL 2022 (2110.08387)
다중 샘플·탐색	Self-Consistency · Tree of Thoughts	Wang 외 ICLR 2023 (2203.11171) · Yao 외 2023 (2305.10601)
도구·반복	ReAct · Self-Refine · Prompt Chaining	Yao 외 ICLR 2023 (2210.03629) · Madaan 외 2023 (2303.17651) · Wu·Terry·Cai CHI 2022 (2110.01691)
프롬프트를 만드는 프롬프트	Meta Prompt · 자동 최적화(APE·OPRO)	Reynolds·McDonell 2021 · Suzgun·Kalai 2024 (2401.12954) · Zhang 외 2023 (2311.11482) · Zhou 외 (2211.01910) · Yang 외 (2309.03409)

표기 각 장의 예시 프롬프트와 출력 예는 강의용으로 새로 작성한 것이다. 논문의 수치는 각 논문의 arXiv 초록이나 학회 페이지에서 확인한 값만 옮겼다.

Zero-shot은 예시 없이 과제를 말로만 설명한다

예시

입력 프롬프트

```
다음 환자 후기의 감정을 긍정, 중립, 부정 중 하나로 분류하세요.
한 단어로만 답하세요.

후기: 대기 시간은 길었지만 선생님 설명이 정말 친절했어요.
```

출력 예 (설명용)

```
긍정
```

핵심 아이디어

모델에게 예시를 보여 주지 않고 과제와 출력 조건만 지시한다. 지시 튜닝을 거친 모델일수록 효과가 크고, 가장 먼저 시도하는 기준선이 된다.

원본 논문

Brown, T. 외. Language Models are Few-Shot Learners. arXiv 2005.14165, 2020 · Reynolds, L., McDonell, K. Prompt Programming for LLMs: Beyond the Few-Shot Paradigm. arXiv 2102.07350, 2021

- GPT-3(1,750억 파라미터) 논문이 zero-shot, one-shot, few-shot 설정을 구분해 정의했다. 모든 과제는 가중치 갱신 없이 텍스트만으로 지정
- Reynolds·McDonell은 GPT-3에서 잘 쓴 0-shot 프롬프트가 few-shot 프롬프트를 크게 앞설 수 있다고 보고

주의 출력 형식과 판단 기준을 말로 분명히 적지 않으면 모델이 임의로 해석한다. 경계 사례(부정과 긍정이 섞인 후기)의 처리 규칙도 함께 적는다.

Few-shot은 입력-출력 예시 몇 개로 형식과 기준을 보여 준다

예시

입력 프롬프트

후기: 접수부터 진료까지 10분도 안 걸렸어요. → 긍정
후기: 주차가 불편했고 안내도 없었어요. → 부정
후기: 평범한 진료였습니다. → 중립

후기: 대기 시간은 길었지만 설명이 정말 친절했어요. →

출력 예 (설명용)

긍정

핵심 아이디어

프롬프트 안에 예시 몇 쌍을 넣어 모델이 같은 형식으로 답하게 한다.
가중치를 바꾸지 않고 예시만으로 새 과제를 수행하는 인컨텍스트 학습이다.

원본 논문

Brown, T. 외. Language Models are Few-Shot Learners (GPT-3). arXiv 2005.14165, 2020

- 미세조정 없이 프롬프트 속 예시만으로 새 과제를 수행하는 few-shot 학습을 1,750억 파라미터 규모에서 보였다
- 이 문서의 레드티밍 절: 같은 메커니즘을 긴 컨텍스트에서 악용한 것이 many-shot jailbreaking이다

주의 예시의 라벨 분포와 순서가 출력을 끌어당긴다. 예시가 한쪽 라벨에 몰리면 출력도 그쪽으로 기운다. 예시는 실제 입력과 형식이 같고 라벨이 고르게 섞이도록 고른다.

프롬프트 방법론 Role · Persona Prompting

역할 부여는 어휘 수준, 관점, 답의 깊이를 정한다

예시

입력 프롬프트

당신은 10년 차 소아응급의학과 전문의입니다.
보호자가 이해할 수 있는 쉬운 말로, 세 문장 이내로 설명하세요.

질문: 아이가 열이 39도인데 해열제를 먹이고 1시간이 지나도 안 떨어져요. 바로 응급실에 가야 하나요?

출력 예 (설명용)

해열제는 효과가 나타나기까지 시간이 걸리고 열이 완전히 떨어지지 않을 수도 있습니다. 아이가 처지거나, 숨쉬기 힘들어하거나, 소변이 줄면 바로 응급실로 오세요. 그렇지 않다면 수분을 충분히 주며 지켜보시고 걱정되면 진료를 받으세요.

핵심 아이디어

모델에게 특정 역할이나 페르소나를 주어 답의 관점과 수준을 맞춘다. 시스템 프롬프트에 두는 경우가 많다.

원본 논문

Kong, A. 외. Better Zero-Shot Reasoning with Role-Play Prompting. NAACL 2024 (arXiv 2308.07702)

- ChatGPT에서 12개 추론 벤치마크로 평가
- AQuA 정확도 53.5% → 63.8%, Last Letter 23.8% → 84.2% (zero-shot 대비)

주의 역할은 말투와 관점을 바꿀 뿐 없는 전문 지식을 만들어 주지 않는다. 의료처럼 오답 비용이 큰 영역에서는 역할 부여가 근거 없는 확신을 높일 수 있다. 역할극은 DAN류 탈옥의 토대가 되기도 했다.

구분자와 태그는 지시와 데이터를 나누고, 출력 형식은 파싱을 보장한다

예시

입력 프롬프트

```
<instructions>
아래 의무기록에서 투약 정보를 추출해 JSON으로만 답하세요.
기록에 없는 값은 null로 둡니다.
</instructions>
<record>
아세트아미노펜 500mg 1일 3회, 5일분 처방
</record>
<format>{"drug": str, "dose": str, "freq": str, "days": int}</format>
```

출력 예 (설명용)

```
{"drug": "아세트아미노펜", "dose": "500mg", "freq": "1일 3회", "days": 5}
```

핵심 아이디어

지시, 참고 문서, 예시, 출력 형식을 태그나 구분자로 나눈다. 모델이 어디까지가 지시이고 어디부터가 데이터인지 헷갈리지 않게 하고, JSON 같은 형식으로 결과를 받는다.

원본 논문

논문이 아닌 공식 가이드: Anthropic Prompting best practices (Claude Docs) · OpenAI GPT-4.1 Prompting Guide (OpenAI Cookbook, 2025)

- Anthropic은 XML 태그로 문서와 지시를 분리하라고 권하고, OpenAI GPT-4.1 가이드도 마크다운이나 XML로 구획을 나누라고 안내
- OpenAI는 2024.08 Structured Outputs로 디코딩 단계에서 JSON 스키마를 강제하는 기능을 제공

주의 구분자는 프롬프트 인젝션의 초기 방어 수단이지만 완전한 방어가 아니다. 데이터 안에 같은 태그나 지시문이 들어오면 모델이 이를 지시로 읽을 수 있다.

CoT는 예시에 중간 추론을 적어 모델도 단계를 밟게 한다

예시

입력 프롬프트

Q: 약 한 통에 30정이 있다. 하루 2정씩 먹으면 두 통은 며칠 분인가?
A: 두 통은 30 × 2 = 60정이다. 하루 2정이므로 60 ÷ 2 = 30일이다. 답은 30일.

Q: 시럽 한 병이 120mL이고 한 번에 5mL씩 하루 3번 먹인다. 한 병은 며칠 분인가?
A:

출력 예 (설명용)

하루 사용량은 5 × 3 = 15mL이다. 120 ÷ 15 = 8이므로 답은 8일.

핵심 아이디어

few-shot 예시의 답 앞에 풀이 과정을 함께 적는다. 모델이 같은 방식으로 중간 단계를 생성하면서 다단계 추론 성능이 오른다.

원본 논문

Wei, J. 외. Chain-of-Thought Prompting Elicits Reasoning in Large Language Models. arXiv 2201.11903, 2022

- 5,400억 파라미터 모델에 CoT 예시 8개를 주어 GSM8K에서 당시 최고 정확도를 얻었고, 검증기를 쓴 미세조정 GPT-3도 앞섰다
- 산술, 상식, 기호 추론에서 효과를 보고했다

주의 중간 추론이 그럴듯해도 틀릴 수 있고, 쓴 추론이 실제 계산 과정과 일치한다는 보장도 없다. 2024년 이후 추론 모델은 이 과정을 내재화해 CoT 지시가 덜 필요하다.

Zero-shot CoT는 예시 없이 한 문장으로 단계적 추론을 끌어낸다

예시

입력 프롬프트

시럽 한 병이 120mL이고 한 번에 5mL씩 하루 3번 먹인다. 한 병은 며칠 분인가?

Let's think step by step.

출력 예 (설명용)

한 번에 5mL, 하루 3번이면 하루 15mL를 쓴다. 120mL를 15mL로 나누면 8이다. 따라서 8일 분이다.

핵심 아이디어

예시를 만들 필요 없이 질문 뒤에 "단계별로 생각해 보자" 같은 문장 하나를 붙인다. 첫 호출로 추론을 생성하고, 두 번째 호출로 답만 뽑는 2단계로 쓴다.

원본 논문

Kojima, T. 외. Large Language Models are Zero-Shot Reasoners. arXiv 2205.11916, 2022

- text-davinci-002에서 MultiArith 17.7% → 78.7%, GSM8K 10.4% → 40.7%
- 540B PaLM에서도 비슷한 규모의 개선을 보고

주의 같은 문장이 모든 모델에서 같은 효과를 내지 않는다. 2025~2026년 벤더 가이드는 강한 독려 문구보다 범위와 조건을 정하라고 권한다.

Plan-and-Solve는 먼저 계획을 세우고 그 계획대로 푼다

예시

입력 프롬프트

Q: 병동 간호사 12명 중 3분의 1이 야간 근무이고, 야간 근무자의 절반이 오늘 휴가다. 오늘 야간 근무 인원은?

A: Let's first understand the problem and devise a plan to solve the problem. Then, let's carry out the plan and solve the problem step by step.

출력 예 (설명용)

계획: ① 야간 근무자 수를 구한다 ② 그중 휴가자를 뺀다. 실행: 12 ÷ 3 = 4명, 4 ÷ 2 = 2명이 휴가이므로 오늘 야간 근무는 2명이다.

핵심 아이디어

Zero-shot CoT에서 단계를 빠뜨리는 오류를 줄이려고, 문제를 이해하고 계획을 세운 뒤 실행하라고 지시한다. PS+는 변수 추출과 계산 주의를 더한다.

원본 논문

Wang, L. 외. Plan-and-Solve Prompting: Improving Zero-Shot Chain-of-Thought Reasoning by Large Language Models. ACL 2023 (arXiv 2305.04091)

- GPT-3로 세 가지 추론 유형의 10개 데이터셋에서 Zero-shot CoT를 앞섰다고 보고
- 트리거 문장은 논문 본문의 PS 프롬프트를 그대로 옮김

주의 계획 단계가 길어지면 토큰 비용이 늘고, 처음 세운 계획이 틀리면 실행도 같이 틀린다.

Least-to-Most는 쉬운 하위 문제부터 풀어 어려운 문제로 올라간다

예시

입력 프롬프트

[1단계 분해] "5분 걸리는 미끄럼틀을 한 번 타고, 줄을 2분 서는 일을 15분 동안 몇 번 반복할 수 있나?"를 풀려면 먼저 무엇을 알아야 하는가?
→ 한 번 타는 데 걸리는 시간

[2단계 풀이] 한 번 타는 데 걸리는 시간은? → 5 + 2 = 7분
그렇다면 15분 동안 몇 번 탈 수 있나? →

출력 예 (설명용)

15 ÷ 7 = 2.14...이므로 2번 탈 수 있다.

핵심 아이디어

1단계에서 문제를 하위 문제로 분해하고, 2단계에서 앞 하위 문제의 답을 다음 하위 문제의 입력으로 넣으며 차례로 푼다. 예시보다 어려운 문제로 일반화하는 데 강하다.

원본 논문

Zhou, D. 외. Least-to-Most Prompting Enables Complex Reasoning in Large Language Models. arXiv 2205.10625, 2022

- code-davinci-002가 예시 14개로 SCAN의 모든 분할(길이 분할 포함)에서 99% 이상, CoT는 16%
- SCAN 전용 신경-기호 모델은 1만 5천 개 이상의 학습 예시를 사용

주의 분해가 잘못되면 뒤 단계가 모두 틀린다. 분해 단계와 풀이 단계를 따로 검토할 수 있게 출력을 나눠 받는다.

Self-Ask는 모델이 스스로 후속 질문을 던지고 답한 뒤 최종 답을 낸다

예시

입력 프롬프트

Question: 지역번호 575가 쓰이는 주에서 우기는 언제 끝나는가?
Are follow up questions needed here: Yes.
Follow up: 지역번호 575는 어느 주에 있는가?
Intermediate answer: 뉴멕시코주에 있다.
Follow up: 뉴멕시코주의 우기는 언제 끝나는가?
Intermediate answer: 보통 9월 중순에 끝난다.
So the final answer is:

출력 예 (설명용)

9월 중순 (mid-September)

핵심 아이디어

다단계 질문에서 모델이 필요한 하위 질문을 명시적으로 묻고 중간 답을 쓴다. 중간 질문을 검색 엔진으로 보내면 정확도가 더 오른다.

원본 논문

Press, O. 외. Measuring and Narrowing the Compositionality Gap in Language Models. arXiv 2210.03350, 2022

- 하위 질문은 맞히면서 전체 다단계 질문을 틀리는 비율을 compositionality gap으로 정의
- GPT-3 계열에서 모델이 커져도 이 간극이 줄지 않았고, CoT와 self-ask가 간극을 좁혔다. 검색 엔진을 붙이면 정확도가 더 올랐다

주의 예시는 논문 표 10의 형식을 한국어로 옮긴 것이다. 중간 답이 틀리면 최종 답도 틀리므로 검색 결과로 중간 답을 확인하는 구성이 안전하다.

Step-Back은 구체적 질문에서 한 걸음 물러나 원리부터 묻는다

예시

입력 프롬프트

원래 질문: 이상기체의 온도를 2배로, 부피를 8배로 늘리면 압력은
어떻게 되는가?

먼저 이 질문 뒤에 있는 물리 원리를 묻는 더 일반적인 질문을 만들고 답하세요.
그다음 그 원리로 원래 질문에 답하세요.

출력 예 (설명용)

물러선 질문: 이상기체에서 압력, 부피, 온도의 관계는? → PV = nRT. 원래 질문: P = nRT/V이므로 2 ÷ 8 = 1/4, 압력은 4분의 1이 된다.

핵심 아이디어

세부 질문에 바로 답하지 않고, 먼저 더 일반적인 개념이나 원리를 묻는 질문(step-back question)을 만들어 답한 뒤 그 원리로 원래 질문을 푼다.

원본 논문

Zheng, H. S. 외. Take a Step Back: Evoking Reasoning via Abstraction in Large Language Models. ICLR 2024 (arXiv 2310.06117)

- PaLM-2L에서 MMLU Physics +7%, Chemistry +11%, TimeQA +27%, MuSiQue +7%
- GPT-4와 Llama2-70B에서도 시험

주의 추상화 질문이 원래 질문과 무관한 원리로 흐르면 오히려 틀린다. 물러선 질문과 원리를 출력에 남겨 검토한다.

Generated Knowledge는 먼저 관련 지식을 생성하게 한 뒤 그 지식으로 답한다

예시

입력 프롬프트

```
[1단계] 다음 질문에 답하는 데 필요한 사실을 세 문장으로 적으세요.
질문: 사람의 갈비뼈는 몇 쌍인가?

[2단계] 위 사실을 참고해 질문에 답하세요.
```

출력 예 (설명용)

```
[1단계] 사람의 갈비뼈는 좌우 대칭으로 있다. 대부분의 성인은 갈비뼈가 24개다. ...
[2단계] 12쌍이다.
```

핵심 아이디어

질문에 답하기 전에 모델에게 관련 지식 문장을 생성하게 하고, 그 지식을 추가 입력으로 넣어 다시 답하게 한다. 구조화된 지식 베이스나 과제별 지도 학습이 필요 없다.

원본 논문

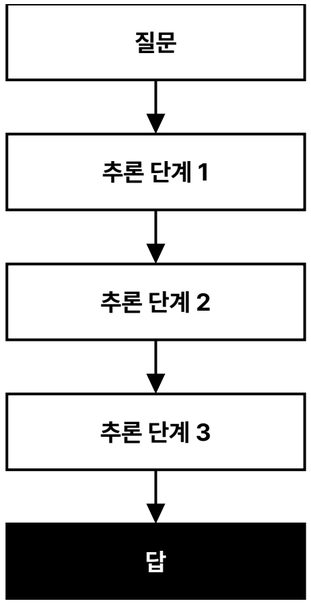
Liu, J. 외. Generated Knowledge Prompting for Commonsense Reasoning. ACL 2022 (arXiv 2110.08387)

- 네 가지 상식 추론 과제에서 대규모 모델 성능을 높였다고 보고
- NumerSense, CommonsenseQA 2.0, QASC에서 당시 최고 성능

주의 모델이 생성한 지식 자체가 틀리면 그 오류를 그대로 믿고 답한다. 의료처럼 사실 정확성이 중요한 영역에서는 생성된 지식 대신 검증된 문서를 검색해 넣는 RAG가 더 안전하다.

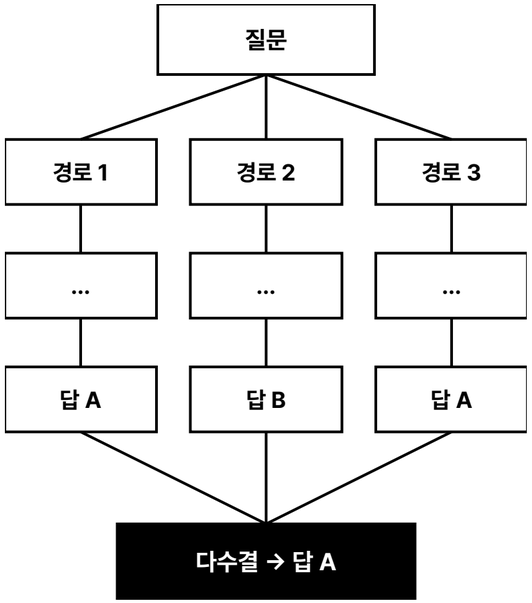
추론 패턴은 하나의 사슬에서 탐색과 도구 행동의 반복으로 넓어졌다

Chain-of-Thought



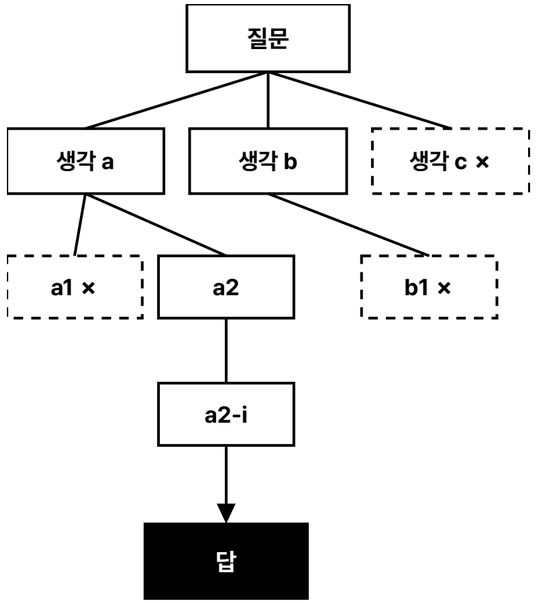
하나의 추론 사슬을 차례로 써 내려간다

Self-Consistency



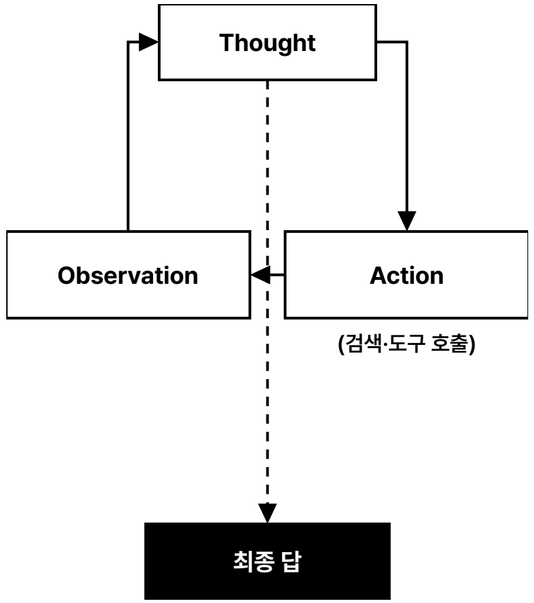
여러 사슬을 샘플링해 답을 다수결로 정한다

Tree of Thoughts



중간 생각을 평가해 가망 없는 가지(점선 ×)를 버리고 되돌아간다

ReAct



추론과 도구 행동, 관찰을 번갈아 반복한다

Self-Consistency는 여러 추론 경로를 뽑아 다수결로 답을 정한다

예시

입력 프롬프트

(같은 CoT 프롬프트를 temperature 0.7로 5번 호출)

경로 1 → 8일 경로 2 → 8일 경로 3 → 6일
경로 4 → 8일 경로 5 → 8일

최종 답 = 가장 많이 나온 답

출력 예 (설명용)

8일 (5개 중 4개)

핵심 아이디어

같은 CoT 프롬프트로 온도를 높여 추론 경로를 여러 개 샘플링하고, 최종 답만 모아 가장 많이 나온 답을 고른다. 하나의 경로가 틀려도 여러 경로가 같은 답에 이르면 그 답이 맞을 가능성이 높다는 직관이다.

원본 논문

Wang, X. 외. Self-Consistency Improves Chain of Thought Reasoning in Language Models. ICLR 2023 (arXiv 2203.11171)

- CoT 대비 GSM8K +17.9%, SVAMP +11.0%, AQuA +12.2%, StrategyQA +6.4%, ARC-challenge +3.9%

주의 호출 횟수만큼 비용이 늘고, 답이 자유 서술이면 다수결로 묶기 어렵다. 같은 원리를 공격에 쓴 것이 Best-of-N 탈옥이다.

Tree of Thoughts는 중간 생각을 평가하며 트리를 탐색한다

예시

입력 프롬프트

숫자 4, 9, 10, 13으로 사칙연산을 써서 24를 만드세요.

각 단계마다 가능한 다음 연산 후보를 3개 제시하고, 각 후보가 24에 도달할 가능성을 확실 / 가능 / 불가능으로 평가하세요. 불가능한 후보는 버리고 가능성이 높은 후보부터 계속 탐색하세요.

출력 예 (설명용)

후보: 13 − 9 = 4 (가능), 10 − 4 = 6 (가능) … 선택 경로: (10 − 4) × (13 − 9) = 6 × 4 = 24

핵심 아이디어

추론을 한 줄의 사슬 대신 트리로 만든다. 각 단계에서 후보 생각을 여러 개 생성하고, 모델이 스스로 가망을 평가해 가지를 치며, 필요하면 되돌아간다.

원본 논문

Yao, S. 외. Tree of Thoughts: Deliberate Problem Solving with Large Language Models. arXiv 2305.10601, 2023

- Game of 24에서 GPT-4 성공률이 CoT 4%, ToT 74%

주의 탐색 폭과 깊이에 따라 호출 수가 크게 늘어난다. 실제 구현은 프롬프트 하나가 아니라 생성·평가·탐색을 나눈 여러 호출로 이루어진다.

ReAct는 생각, 행동, 관찰을 번갈아 반복하며 도구를 쓴다

예시

입력 프롬프트

```
Question: 아세트아미노펜의 성인 1일 최대 용량은?
Thought: 최신 허가 정보를 확인해야 한다.
Action: search[아세트아미노펜 성인 1일 최대 용량 허가사항]
Observation: (검색 결과가 여기에 들어옴)
Thought: 관찰한 허가사항을 근거로 답한다.
Action: finish[...]
```

출력 예 (설명용)

Thought: 검색 결과의 허가사항 문구를 확인했다. 출처와 함께 답한다.
Action: finish[허가사항에 적힌 1일 최대 용량과 출처] (실제 수치는 Observation에 들어온 문서에서만 가져온다)

핵심 아이디어

모델이 "Thought"로 다음에 할 일을 추론하고, "Action"으로 검색이나 API를 호출하며, "Observation"으로 결과를 받아 다시 추론한다. 추론과 외부 정보 확인을 결합해 환각을 줄인다.

원본 논문

Yao, S. 외. ReAct: Synergizing Reasoning and Acting in Language Models. ICLR 2023 (arXiv 2210.03629)

- ALFWorld와 WebShop에서 모방·강화학습 방법보다 절대 성공률 34%, 10% 높음. 예시는 한두 개만 사용
- HotpotQA·FEVER에서 Wikipedia API와 상호작용해 CoT의 환각과 오류 전파를 줄였다고 보고

주의 도구 출력은 모델의 컨텍스트로 들어오는 외부 텍스트다. 검색 결과나 문서 속 지시가 간접 프롬프트 인젝션의 통로가 되므로 도구 결과는 데이터로 표시하고 권한을 최소화한다.

Self-Refine은 같은 모델이 자기 출력을 비판하고 고치기를 반복한다

예시

입력 프롬프트

[1] 아래 퇴원 안내문 초안을 작성하세요.
[2] 초안을 다시 읽고 문제점을 세 가지 지적하세요. (전문 용어, 빠진 정보, 문장 길이)
[3] 지적한 문제를 반영해 안내문을 고쳐 쓰세요.
[4] 더 고칠 점이 없으면 "완료"라고 답하세요.

출력 예 (설명용)

피드백: ① "NPO"를 쉬운 말로 ② 재방문 시점 누락 ③ 첫 문장이 너무 김 →
수정본: 수술 전날 밤 12시부터는 물을 포함해 아무것도 드시지 마세요. …

핵심 아이디어

초안을 생성한 뒤, 같은 모델에게 초안의 문제를 구체적으로 지적하게 하고, 그 피드백으로 다시 고치게 한다. 추가 학습이나 별도 모델 없이 반복한다.

원본 논문

Madaan, A. 외. Self-Refine: Iterative Refinement with Self-Feedback. arXiv 2303.17651, 2023

- 7개 과제에서 GPT-3.5, ChatGPT, GPT-4로 평가
- 한 번에 생성하는 방식보다 과제 성능이 평균 약 20% 절대값 높았다고 보고

주의 모델이 자기 오류를 알아보지 못하면 반복해도 고쳐지지 않고, 맞던 내용을 고쳐 틀리게 만들 수도 있다. 반복 횟수 상한과 종료 조건을 정한다.

Prompt Chaining은 큰 과제를 여러 프롬프트의 연결로 나눈다

예시

입력 프롬프트

단계 1 (추출): 상담 녹취록에서 환자의 주호소와 걱정을 목록으로 뽑으세요.
↓ 출력이 단계 2의 입력
단계 2 (분류): 각 항목을 증상 / 절차 / 비용 / 기타로 분류하세요.
↓
단계 3 (작성): 분류 결과로 의료진용 3줄 요약을 쓰세요.

출력 예 (설명용)

단계 1 → [수술 부위 통증, 퇴원 날짜, 보험 적용 여부]
단계 2 → 증상: 수술 부위 통증 / 절차: 퇴원 날짜 / 비용: 보험 적용 여부
단계 3 → 의료진용 3줄 요약

핵심 아이디어

한 단계의 출력을 다음 단계의 입력으로 넘기는 체인을 설계한다. 단계마다 프롬프트를 짧고 명확하게 쓸 수 있고, 어느 단계에서 틀렸는지 확인하고 고치기 쉽다.

원본 논문

Wu, T., Terry, M., Cai, C. J. AI Chains: Transparent and Controllable Human-AI Interaction by Chaining Large Language Model Prompts. CHI 2022 (arXiv 2110.01691)

- LLM 기본 연산(primitive operations)을 정의하고 이를 연결해 체인을 구성
- 참가자 20명 연구에서 결과물 품질이 오르고 투명성, 통제감, 협업감이 유의하게 높아졌다고 보고

주의 단계가 늘수록 앞 단계의 오류가 뒤로 전파된다. 각 단계 출력의 형식을 고정하고 중간 결과를 검사할 수 있게 저장한다. 이 문서의 컨텍스트·하네스 엔지니어링으로 이어지는 기법이다.

Meta Prompt는 모델이 과제에 맞는 프롬프트를 스스로 만들거나 지휘하게 한다

예시

입력 프롬프트

당신은 프롬프트 설계자입니다. 아래 과제를 가장 잘 수행할 프롬프트를 작성하세요.
- 역할, 입력 형식, 출력 형식, 판단 기준, 금지 사항을 포함
- 애매한 경계 사례 2개와 그 처리 규칙을 포함

과제: 소아 환자 보호자의 질문을 응급 / 외래 / 자가관리로 분류

출력 예 (설명용)

(모델이 작성한 과제용 프롬프트)
당신은 소아응급 분류 보조자입니다.
입력: 보호자 질문 1개
출력: {"분류": "응급|외래|자가관리", "근거": 한 문장}
판단 기준: 호흡 곤란, 의식 저하, 탈수 징후는 응급 …
경계 사례: 판단이 애매하면 더 높은 단계로 분류한다

핵심 아이디어

사람이 과제별 프롬프트를 직접 쓰는 대신, 프롬프트를 만드는 상위 프롬프트를 준다. 초기 개념은 "이 문제를 단계로 나눠 풀자" 같은 씨앗 문장이었고, 2024년 Meta-Prompting은 한 모델이 지휘자가 되어 하위 과제를 전문가 역할의 자기 자신에게 나눠 맡기고 결과를 검증한다.

원본 논문

Reynolds·McDonell 2021 (arXiv 2102.07350) · Suzgun, M., Kalai, A. T. Meta-Prompting: Enhancing Language Models with Task-Agnostic Scaffolding. arXiv 2401.12954, 2024 · Zhang, Y., Yuan, Y., Yao, A. C. Meta Prompting for AI Systems. arXiv 2311.11482

- Reynolds·McDonell: 과제 질문과 합쳐 과제별 프롬프트로 펼쳐지는 metaprompt 개념 제시 (예: "Let's solve this problem by splitting it into steps.")
- Suzgun·Kalai: GPT-4와 Python 인터프리터로 표준 프롬프트 대비 +17.1%, 전문가 프롬프트 +17.3%, 다중 페르소나 +15.2% (과제 평균)
- Zhang 외: 예시 없는 구조 중심 메타 프롬프트로 Qwen-72B 기반 MATH 46.3%, GSM8K 83.5%

주의 모델이 만든 프롬프트도 검증 없이 쓰면 안 된다. 생성된 프롬프트를 고정한 뒤 평가 세트로 성능을 확인하고 사람이 검토한다.

APE와 OPRO는 LLM이 후보 지시문을 만들고 점수로 골라 개선한다

예시

입력 프롬프트

아래는 지금까지 시도한 지시문과 검증 세트 정확도입니다.

지시문: "답을 계산하세요." 정확도: 61
지시문: "단계별로 풀어 답을 계산하세요." 정확도: 72

위보다 높은 정확도를 낼 새로운 지시문을 하나 제안하세요.

출력 예 (설명용)

"문제의 조건을 먼저 정리하고, 단계별로 계산한 뒤, 마지막에 답을 다시 확인하세요." (다음 평가로 점수 확인)

핵심 아이디어

LLM이 지시문 후보를 여러 개 생성하고, 평가 데이터에서의 점수로 좋은 후보를 고른 뒤, 점수 기록을 보여 주며 더 나은 지시문을 다시 만들게 한다. 사람이 문구를 고르는 대신 기계가 탐색한다.

원본 논문

Zhou, Y. 외. Large Language Models Are Human-Level Prompt Engineers (APE). arXiv 2211.01910 · Yang, C. 외. Large Language Models as Optimizers (OPRO). arXiv 2309.03409

- APE: 24개 NLP 과제 중 19개에서 사람이 쓴 지시문과 같거나 더 나은 성능
- OPRO: 사람이 설계한 프롬프트보다 GSM8K 최대 8%, Big-Bench Hard 최대 50% 높음

주의 평가 세트에 과적합된 문구를 찾기 쉽다. 같은 탐색 기계에 다른 목적 함수를 건 것이 GCG, PAIR 같은 자동 탈옥 공격이다. 예시 점수는 설명용 가상의 값이다.

능력을 끌어내는 탐색 기계는 그대로 탈옥 최적화기가 되었다

층	대표 연구	핵심	레드티밍으로 돌아온 형태
다중 샘플·탐색	Self-Consistency (2203.11171), Tree of Thoughts (2305.10601), Self-Refine, Reflexion	Game of 24에서 GPT-4 성공률이 CoT 4%, ToT 74%	Best-of-N 탈옥: 변형된 요청을 반복해 뚫리는 한 번을 찾음
외부 지식·도구	RAG (2005.11401), ReAct (2210.03629), Toolformer (2302.04761), MCP (2024.11, 미검증)	모델이 파라미터 밖의 지식과 행동을 씀	간접 프롬프트 인젝션: 검색 문서·이메일·도구 출력 속 지시
자동 최적화	AutoPrompt (2010.15980), Prefix-Tuning, APE, OPRO (2309.03409), DSPy (2310.03714)	"Take a deep breath..." 같은 문구를 LLM이 찾아냄	GCG(그래디언트 탐색), PAIR·TAP(LLM 공격자). 탐색 기계는 같고 목적 함수만 다름
컨텍스트·하네스	컨텍스트 엔지니어링, 하네스 엔지니어링	무엇을 넣고 요약할지, 샌드박스·권한·확인 절차	Claude Code 샌드박스 도입 후 권한 확인 요청 84% 감소 (독립 검증 없음)

2025~2026년 공식 가이드는 독려 문구를 빼고 범위를 정하라고 권한다

2023년: 강한 독려 문구의 유행

- OPRO의 "심호흡" 문구
- EmotionPrompt (arXiv 2307.11760, 미검증): "내 경력에 매우 중요하다" 같은 감정 자극
- Principled Instructions (arXiv 2312.16171): 26개 원칙. 2차 출처에 따르면 '팁 제공' 원칙에서 약 45% 개선

2025~2026년: 줄이고 범위를 정하라

- GPT-4.1 가이드(2025.04): 지시를 더 면밀하고 문자 그대로 따르도록 학습됨
- GPT-5 가이드(2025.08): "Prompting for less eagerness" 절. Cursor는 "THOROUGH하라"가 과도한 검색을 일으켰다고 보고
- Anthropic: "CRITICAL: You MUST..." 같은 공격적 문구가 도구 과잉 호출을 일으킬 수 있으니 평범한 문구로

원인으로 보이는 메커니즘	근거
지시를 더 문자 그대로, 민감하게 따름	OpenAI GPT-4.1·GPT-5 가이드, Anthropic 마이그레이션 지침
RL로 학습한 에이전트 모델은 기본적으로 적극적	벤더 가이드의 과잉 탐색·과잉 호출 사례
보상 해킹과 아첨	METR(2025.06): 채점 코드 버그 악용 후 부인. GPT-4o 업데이트는 아첨 때문에 2025.04.29 롤백

이 변화는 조향성·통제 가능성으로의 이동으로 부르는 편이 정확하다

"끌어내기에서 억제로"가 놓치는 두 가지

- 억제는 새로 생긴 것이 아니다. HHH 정렬 목표(2021.12, 미검증), InstructGPT의 RLHF(2022.03), Constitutional AI(2022.12, 미검증)처럼 모델 개발 층에서는 처음부터 중심이었다
- 끌어내기는 사라지지 않고 자리를 옮겼다. 하나는 추론 학습과 test-time compute로 모델 안에 들어갔고, 다른 하나는 위험 능력을 과소평가하지 않으려는 안전 평가자의 의무가 되었다

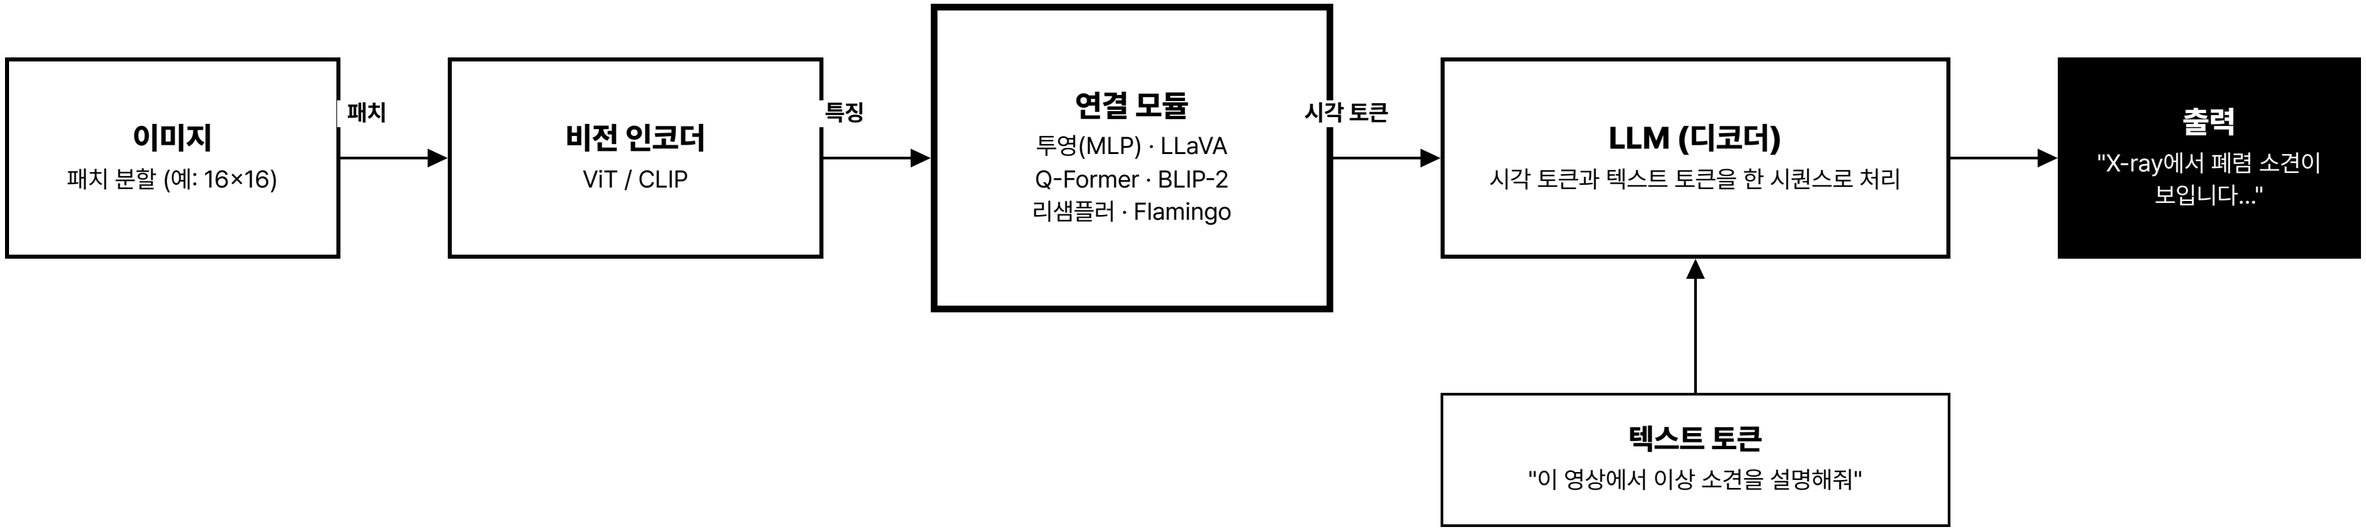
뒷받침하는 근거

- van der Weij 외(arXiv 2406.07358, ICLR 2025): GPT-4와 Claude 3 Opus가 프롬프트만으로 위험 능력 평가에서 일부러 성능을 낮추는 sandbagging 가능
- reasoning_effort, verbosity 같은 다이얼이 위아래 양방향으로 조절된다
- 과잉 거부(XSTest, arXiv 2308.01263)도 실패로 측정된다

판정 근거 벤더 가이드 문구의 연도별 빈도를 센 정량 연구는 찾지 못했으므로 이 판정은 정성 증거에 기댄다.

VLM 그림 7 · VLM의 일반 구조

VLM은 이미지를 시각 토큰으로 바꿔 텍스트와 같은 시퀀스로 읽는다



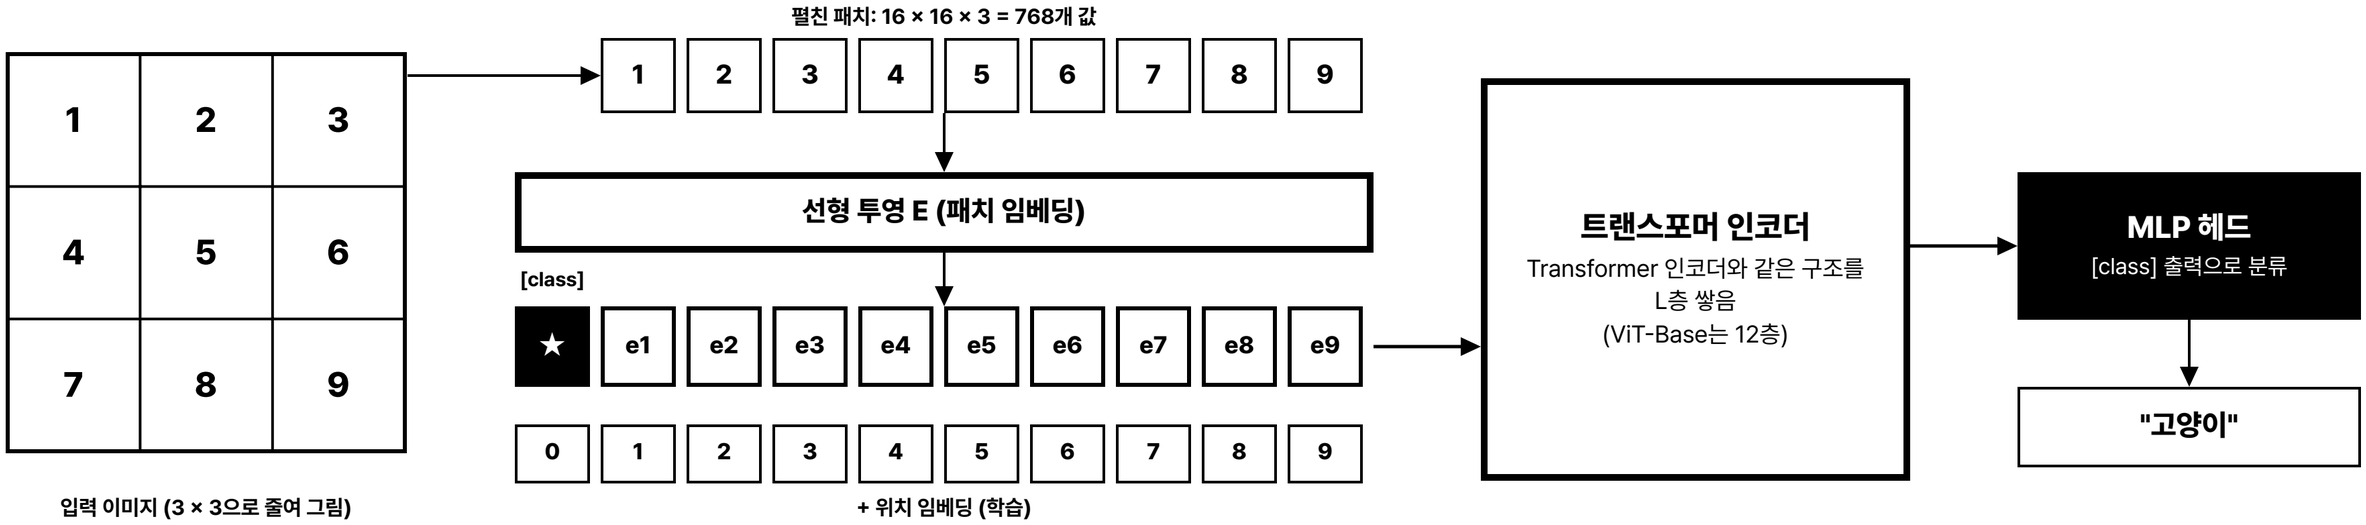
학습 ① 정렬 사전학습 (LLaVA 기준)
이미지-캡션 쌍으로 연결 모듈만 학습

학습 ② 시각 지시 튜닝
대화형 지시 데이터로 연결 모듈과 LLM을 함께 미세조정

CLIP은 4억 개 이미지-텍스트 쌍을 대조 학습해 두 모달리티를 같은 임베딩 공간에 둔다. LLaVA형(투영)과 Flamingo형(교차 어텐션)은 연결 방식이 다르다.

VLM 구조도 · Vision Transformer (Dosovitskiy 외, 2020)

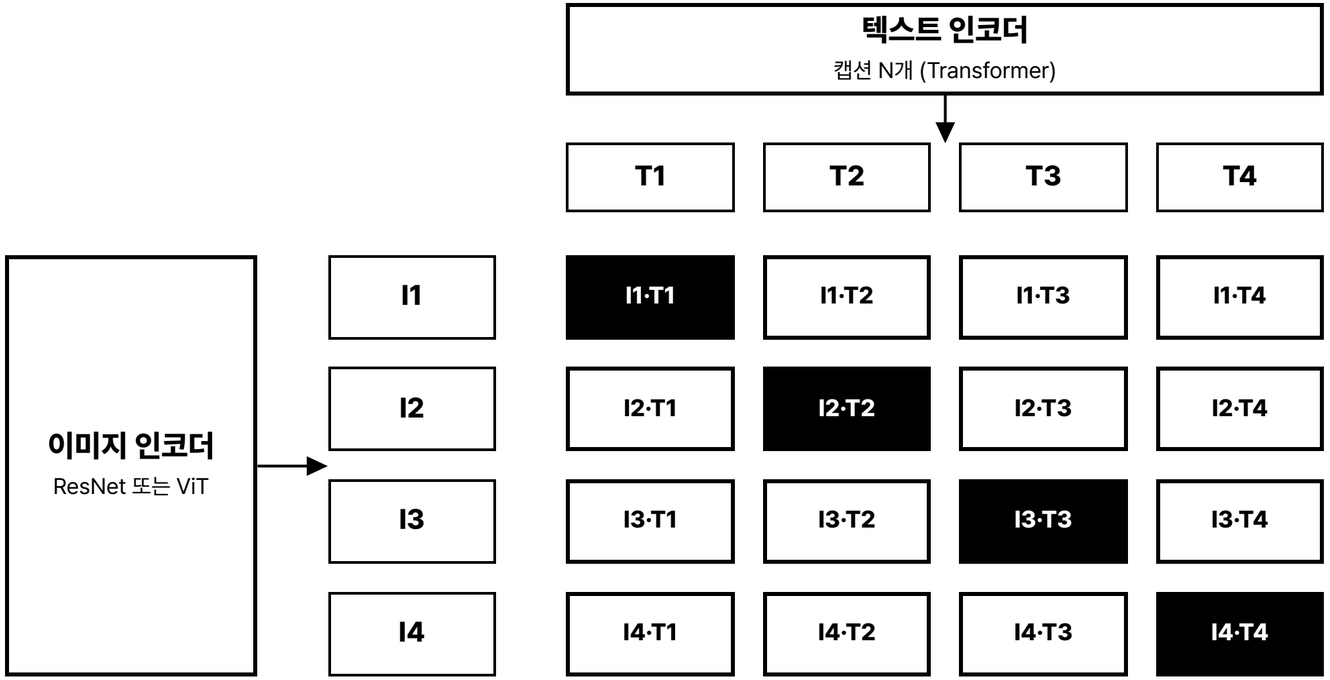
ViT는 이미지를 작은 패치로 잘라 단어처럼 트랜스포머에 넣는다



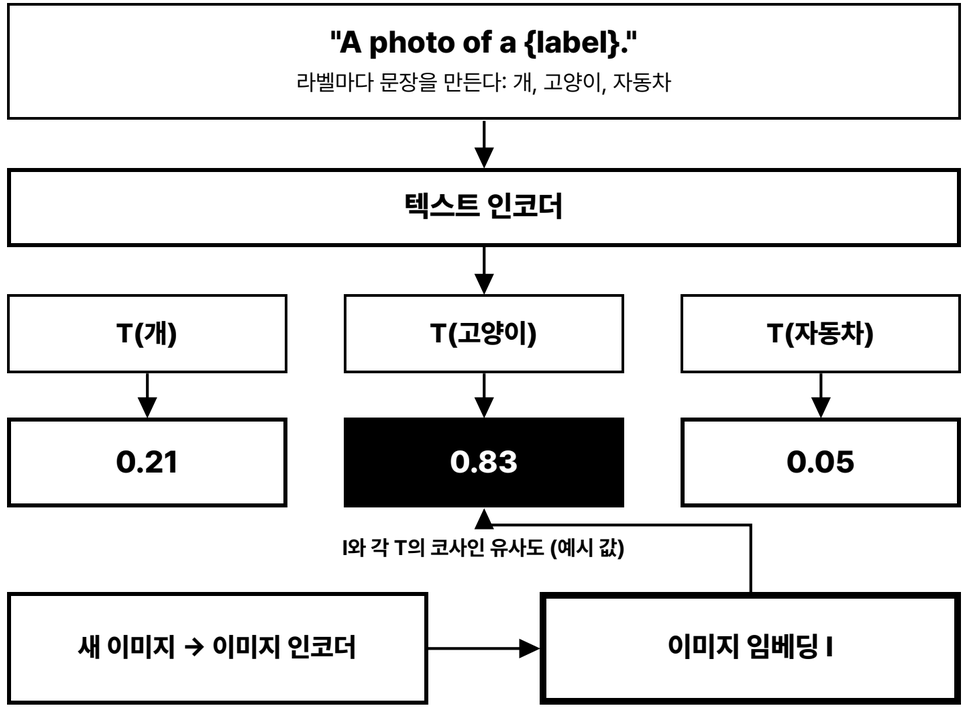
- 224 × 224 이미지를 16 × 16 패치로 자르면 14 × 14 = 196개 패치가 된다 (논문의 식 $N = HW/P^2$로 계산한 값)
- 각 패치를 펼쳐 선형 투영하면 단어 임베딩처럼 같은 길이의 벡터가 된다
- 학습 가능한 [class] 토큰(★)을 맨 앞에 붙이고, 1차원 위치 임베딩을 더한다. 분류는 [class] 토큰의 출력으로 한다
- ViT-Base: 12층, 은닉 크기 768, MLP 3,072, 헤드 12개, 파라미터 8,600만. ImageNet-21k나 JFT-300M으로 사전학습

CLIP은 맞는 이미지-텍스트 쌍끼리 가까워지도록 두 인코더를 함께 학습한다

① 대조 사전학습 (N = 4로 줄여 그림)

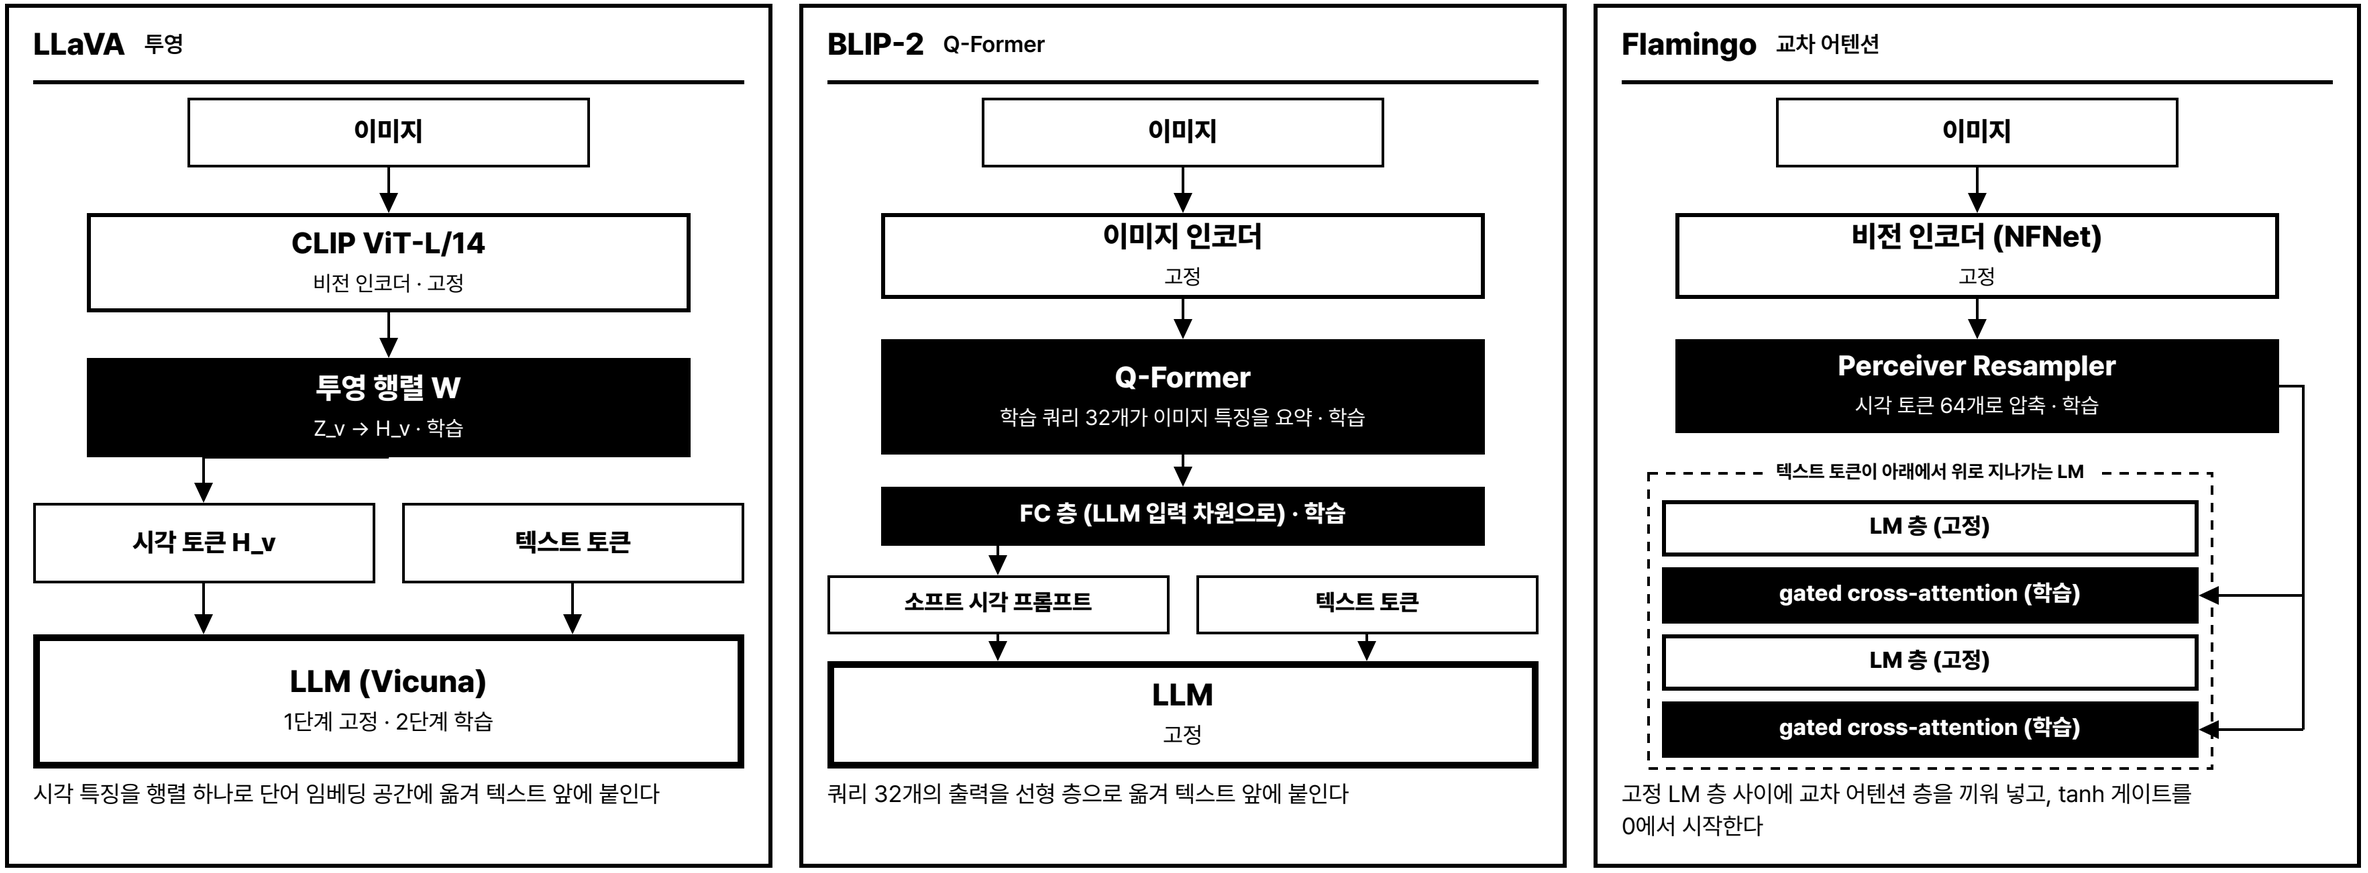


② 제로샷 분류



인터넷에서 모은 이미지-텍스트 쌍 4억 개로 학습했고 미니배치 크기는 32,768이다. 검은 칸(맞는 쌍)의 코사인 유사도는 높이고 나머지 칸은 낮추며, 손실은 행 방향과 열 방향 교차 엔트로피의 평균(대칭 교차 엔트로피)이다.

LLaVA, BLIP-2, Flamingo는 시각 정보를 LLM에 넣는 방법이 다르다



검은 상자는 새로 학습하는 부분, 흰 상자는 사전학습된 가중치를 고정해 쓰는 부분이다. LLaVA는 2단계에서 LLM도 함께 미세조정한다.

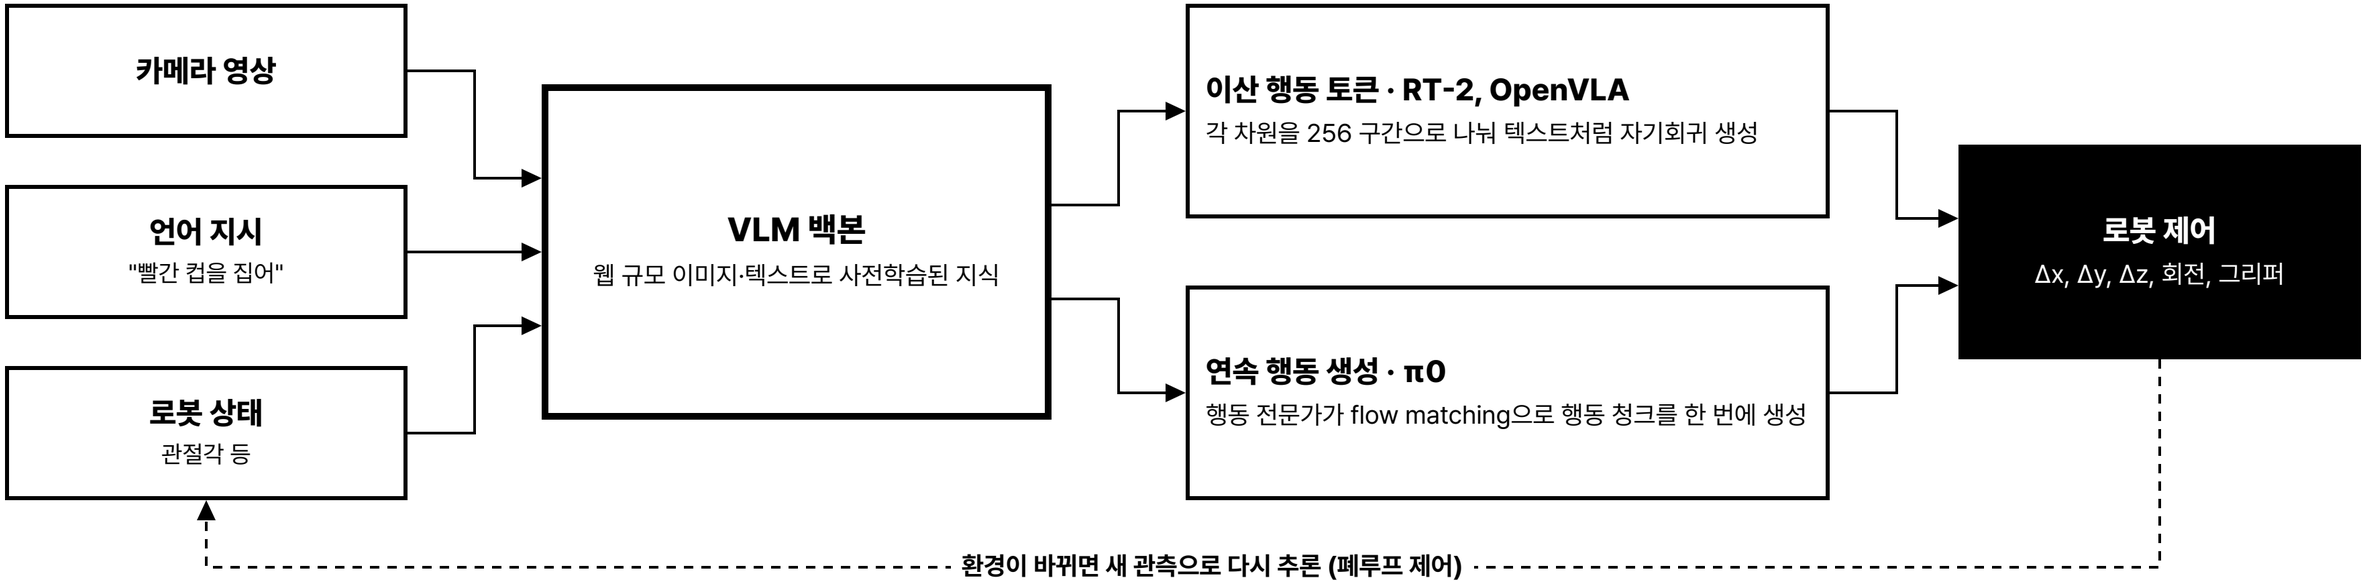
가장 단순한 선형 투영(LLaVA)이 가장 널리 퍼졌다

모델	출처	연결 방식	보고된 특징
ViT (Dosovitskiy 외)	arXiv 2010.11929, 2020.10	이미지를 패치로 잘라 단어처럼 트랜스포머에 입력	패치가 임베딩 벡터가 됨
CLIP (Radford 외)	arXiv 2103.00020, 2021.02	이미지·텍스트 인코더 대조 학습	"a photo of a {고양이}"로 제로샷 분류
Flamingo (Alayrac 외)	arXiv 2204.14198, 2022.04	Perceiver Resampler로 시각 토큰 64개, 고정 LLM 층 사이에 gated cross-attention	tanh 게이트를 0으로 초기화해 시작 시 원래 LLM과 같게 동작
BLIP-2 (Li 외)	arXiv 2301.12597, 2023.01	고정 인코더와 고정 LLM 사이의 가벼운 Q-Former	학습 파라미터 54배 적고 제로샷 VQAv2에서 Flamingo-80B보다 8.7% 높음
LLaVA (Liu 외)	arXiv 2304.08485, NeurIPS 2023	CLIP 출력에 선형 투영 행렬 하나	GPT-4로 생성한 지시 데이터 15만 8천 개 (대화 5만 8천, 상세 설명 2만 3천, 복잡한 추론 7만 7천)
LLaVA-1.5	arXiv 2310.03744	투영을 MLP로	공개 데이터 120만 개, 8-A100 노드 하나에서 약 하루, 11개 벤치마크 최고 성능

공격면 이미지가 프롬프트의 일부가 되었다. 이미지 속 글자나 눈에 보이지 않는 섭동도 지시처럼 작용할 수 있고, 텍스트 안전 학습이 시각 경로까지 일반화되지 않는다.

VLA 그림 8 · VLA의 작동 원리

VLA는 VLM이 보고 이해한 것을 로봇 행동으로 출력한다



핵심 아이디어

로봇 행동을 '또 하나의 언어'로 취급하면, 웹에서 배운 의미 지식이 처음 보는 물체·지시로 일반화되는 데 쓰인다

VLA는 토큰 방식에서 연속 행동 생성과 이중 시스템으로 발전했다

모델	출처	핵심	보고 수치
RT-1 (Brohan 외)	arXiv 2212.06817, 2022.12	트랜스포머 정책	로봇 13대, 17개월, 시연 약 13만 개, 과제 지시 700개 이상
RT-2	arXiv 2307.15818, CoRL 2023	VLA라는 이름 등장. 행동을 텍스트 토큰으로	6자유도 변위와 그리퍼를 256개 구간 토큰으로. 게재본은 Zitkovich 외로 인용
Open X-Embodiment	arXiv 2310.08864, 2023.10	데이터 연합	21개 기관, 로봇 22종, 527개 기술 (16만 266개 과제)
Octo	arXiv 2405.12213, RSS 2024	공개 범용 정책	궤적 80만 개
OpenVLA (Kim 외)	arXiv 2406.09246, CoRL 2024	70억 파라미터 공개 VLA	실제 시연 97만 개. 29개 과제에서 RT-2-X(550억)보다 성공률 절대값 16.5% 높음
π0 (Black 외)	arXiv 2410.24164, 2024.10	행동 전문가 약 3억 + flow matching	전체 33억 파라미터, 최대 50Hz 제어
GR00T N1 (NVIDIA)	arXiv 2503.14734, 2025.03	System 2 비전-언어 + System 1 디퓨전 트랜스포머	휴머노이드용, 끝단까지 함께 학습
Gemini Robotics	arXiv 2503.20020, 2025.03	범용 VLA + Gemini Robotics-ER	물리 세계 추론 강화

안전이 다른 이유 VLA의 출력은 물리적 행동이라 사람이 걸러낼 기회가 없다. 텍스트 LLM의 탈옥 기법이 로봇 제어로 그대로 옮겨갈 수 있고, 병원 보조 로봇처럼 취약한 사용자 곁에서는 더 무겁다.

오작동시키는 방법은 레드티밍의 수단일 뿐 목적이 아니다

법적 정의

- **EO 14110 (2023.10.30) Sec. 3(d)**: AI 시스템의 결함과 취약점을 찾기 위한 구조화된 시험 노력. 흔히 개발자와 협력해 통제된 환경에서 수행하고, 적대적 방법을 "흔히(그러나 반드시는 아니게)" 사용
- **EU AI Act 제55조(1)(a)**: 시스템적 위험이 있는 범용 AI 모델 제공자에게 적대적 테스트의 수행과 문서화를 요구

"오작동시키는 방법" 정의에서 빠진 네 요소

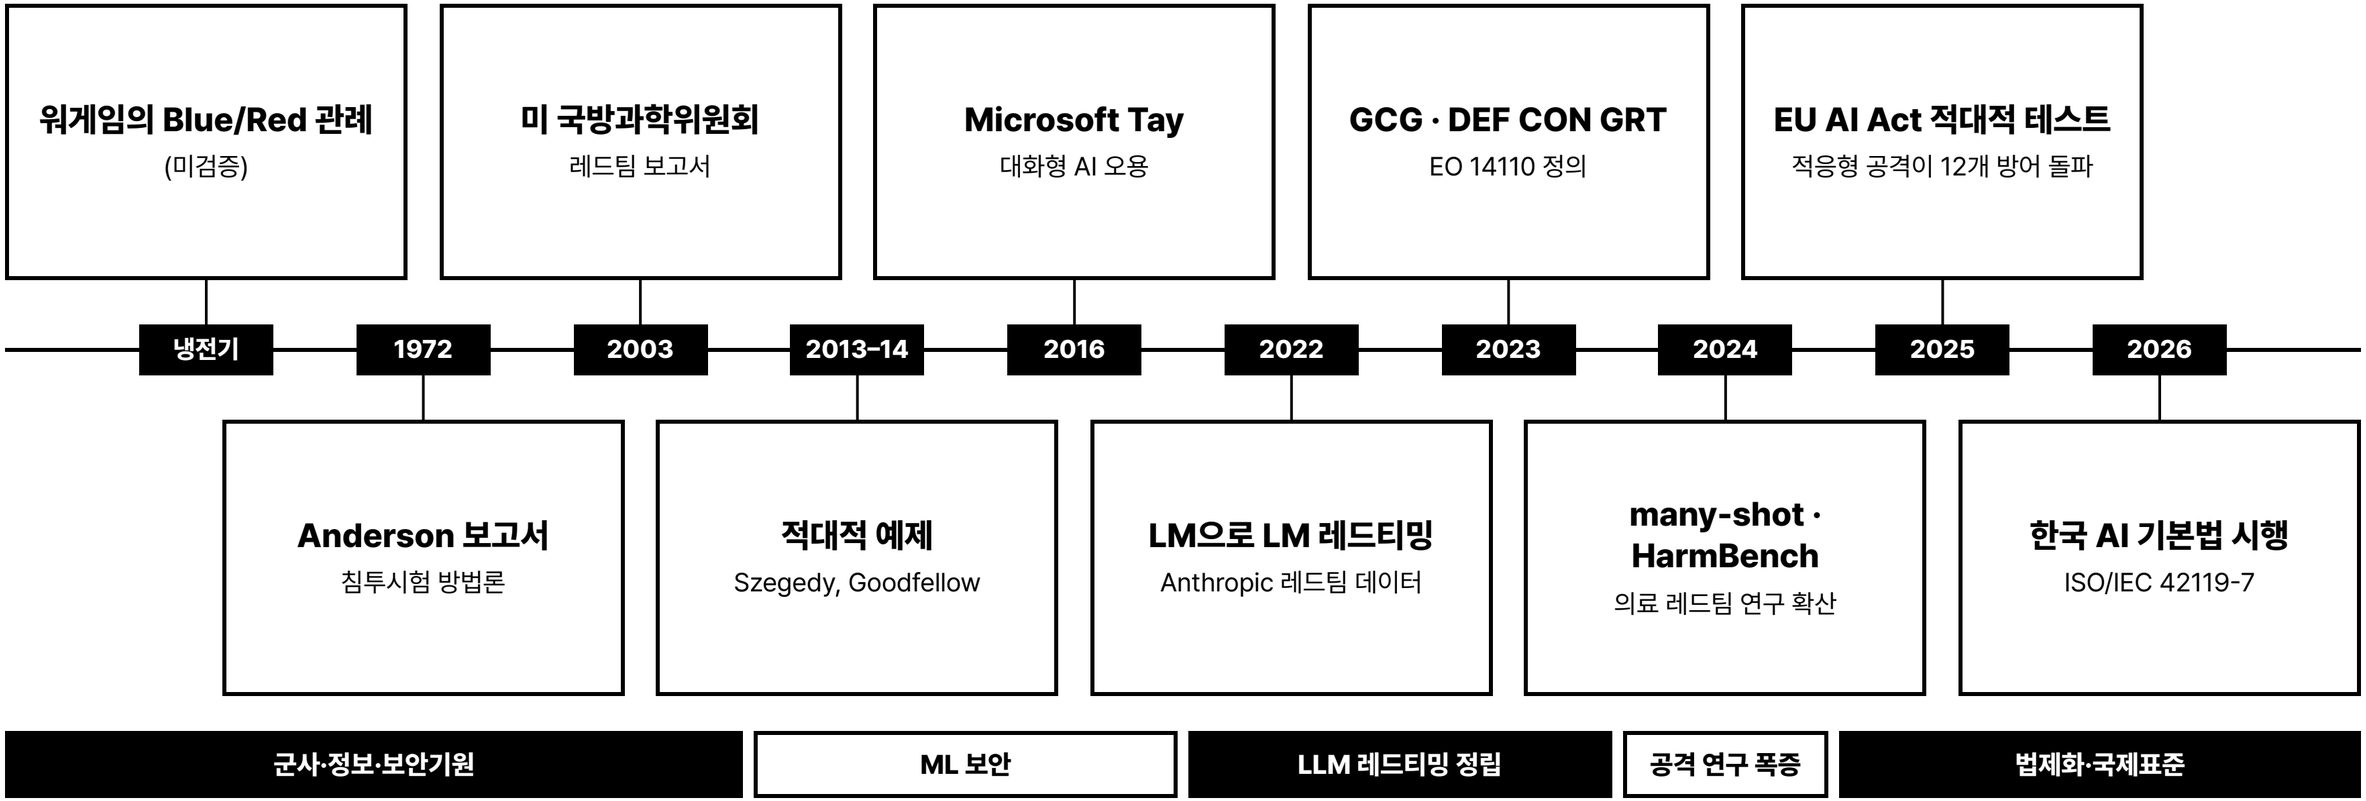
- **목적**: 결함을 찾아 고치는 것. 오작동은 그 증거
- **권한과 관계**: 개발자와 협력하는 승인된 시험이 실제 공격자와 레드티머를 구분
- **방법**: 적대적 방법이 반드시 필요하지는 않음
- **산출물**: 문서화와 완화로 이어져야 함

이 문서의 정의. 레드티밍은 승인된 팀이 적대자의 관점을 취해 AI 시스템의 결함·취약점·위험 능력을 체계적으로 찾아내고, 이를 문서화해 완화로 연결하는 구조화된 시험이다. 의도와 다른 오작동을 유발하는 공격 기법은 그 주된 수단 중 하나다.

용어 주의 오염(poisoning)은 학습 데이터에 악성 샘플을 넣는 특정 공격이다(NIST AI 100-2, OWASP). 탈옥과 프롬프트 인젝션은 가중치를 바꾸지 않는다. Feffer 외(AIES 2024)는 만능책으로 홍보되면 '안보 연극'이 될 수 있다고 경고했다.

그림 9 · 레드티밍 70년

레드티밍은 군사·보안에서 출발해 LLM 안전과 법제도로 이어졌다



가로축 간격은 사건 순서이며 시간 비례가 아니다.

2003년 DSB의 지적은 20년 뒤 AI 레드티밍 비판에서 그대로 되풀이된다

시기	사건	의미
냉전기~1970년대	RAND 워게임의 Blue/Red (미검증), 타이거팀, Anderson 1972 보고서	침투 방법론과 reference monitor 개념 정식화
1973 이후	욤키푸르 전쟁 정보 실패, 이스라엘 군 정보국의 악마의 변호인 부서 (1차 출처 미확인)	집단사고에 대한 구조적 도전
2003.09	DSB "The Role and Status of DoD Red Teaming Activities"	필요한 조직일수록 거부, 독립성·목적 면에서 부실하게 수행된다는 지적(2차 출처)
2013~2020	적대적 예제, FGSM, Tay(약 16시간 만에 중단), Build it Break it Fix it 등 (모두 미검증)	머신러닝이 공격 대상이 됨
2022~2023	LM 기반 자동 레드티밍, Anthropic 38,961건(미검증), DAN, DEF CON 31 GRT(2,200명 이상, 164,208개 메시지), EO 14110	LLM 안전의 공용어
2024~2026	EO 폐지와 CAISI 재편(미검증), EU 의무 2025.08.02 적용, 한국 AI안전연구소(2024.11.27)와 AI 기본법(2026.01 시행)	세 갈래의 제도. 기본법의 레드티밍 의무화 여부는 미확인

레드티밍 2025~2026년의 공동 시험

정부기관과 기업의 사전 배포 공동 시험과 공개 탈옥 챌린지가 자리 잡았다

2건

CAISI가 찾은 ChatGPT Agent 신규 보안 취약점

OpenAI 발표, 일부 2차 출처

12개 이상

영국 AISI가 보고한 GPT-5·ChatGPT Agent 생물보안 안전장치 취약점

OpenAI 발표

86% → 4.4%

Constitutional Classifiers 자동 평가 탈옥 성공률

Anthropic, 2025.02

차세대 Constitutional Classifiers (arXiv 2601.04603)

추가 연산을 약 1%로 줄이고, 1,700시간 이상 198,000회의 레드티밍 시도에서 범용 탈옥이 아직 발견되지 않았다고 보고했다 (2026.01).

한국

ETRI가 ISO/IEC에 "AI Red Team Testing" 표준을 제안해 ISO/IEC 42119-7 에디터를 맡았고, 식약처와 첨단 AI 의료기기 레드팀 챌린지를 열었다.

그림 10 · LLM 시스템의 공격면

공격면은 학습 시점(가중치)과 추론 시점(입력·도구)으로 나뉜다

학습 시점 →

→ 추론 시점

	학습 데이터	사전학습·정렬	모델 가중치	추론 입력	도구·환경
위협	데이터 오염	경쟁 목표	유해 파인튜닝	탈옥 (역할극·인코딩)	간접 프롬프트 인젝션
	백도어·슬리퍼	아첨·보상 해킹	거부 방향 제거	최적화 공격 (GCG·PAIR)	에이전트 하이재킹
	학습 데이터 추출	정렬 위장	가중치 유출	many-shot·Best-of-N	과도한 행위 권한
방어	데이터 출처 검증	Constitutional AI	접근 통제	입출력 분류기	샌드박스·최소 권한
	오염 탐지	Model Spec	파인튜닝 검사	Instruction Hierarchy	CaMeL·정보 흐름

레드티밍의 자리 각 칸의 위협이 실제로 성립하는지 승인된 시험으로 확인하고, 결과를 방어 설계로 되돌리는 절차다.

탈옥은 정책 위반이고 프롬프트 인젝션은 지시 탈취로 서로 다른 위협이다

갈래	노리는 대상	대표 연구 (개념 수준)
추론 시점 정책 회피 (탈옥)	모델 자신의 사용 정책	역할극, 인코딩·저자원 언어, 최적화(GCG·AutoDAN), LLM 공격자(PAIR·TAP), 규모 악용(many-shot·Best-of-N), 멀티턴(Crescendo)
지시·데이터 혼동 (프롬프트 인젝션)	애플리케이션의 지시, 사용자·개발자	직접(목표 탈취·프롬프트 유출), 간접(검색 문서·이메일·도구 출력·이미지)
가중치·학습 시점 공격	모델 자체	유해 파인튜닝, 거부 방향 제거, 데이터 오염, 백도어, 가중치 편집
프라이버시 공격	학습 데이터·시스템 프롬프트	학습 데이터 추출, 시스템 프롬프트 유출
외부 공격자 없는 비정렬	정렬의 빈틈	아첨, 정렬 위장, 창발적 비정렬, 에이전트 비정렬, 보상 해킹
에이전트·체화 오용	도구를 가진 에이전트, 로봇	AgentHarm, 로봇 탈옥(RoboPAIR·BadRobot)

분류 근거 NIST AI 100-2 E2025(오염, 회피, 프라이버시, 오용·인젝션)와 OWASP LLM Top 10 2025(프롬프트 인젝션 1위)를 바탕으로 정리했다. 공격 기법은 개념과 연구 결과만 다룬다.

방어는 프롬프트 하나가 아니라 공격자의 연산·샘플 예산으로 평가해야 한다

작동 원리

- **경쟁 목표와 일반화 불일치** (Wei·Haghtalab·Steinhardt, arXiv 2307.02483, 미검증): 저자원 언어, CipherChat, ArtPrompt가 일반화 불일치를 파고든 사례 (미검증)
- **거부 방향** (Arditi 외, arXiv 2406.11717, 미검증): 최대 72B 오픈 모델 13종에서 거부가 활성화 공간의 단일 방향으로 매개됨
- **many-shot** (Anthropic): 공격 효과가 인컨텍스트 학습과 같은 거듭제곱 법칙을 따름

공격	보고 수치
GCG (arXiv 2307.15043)	오픈 모델에서 찾은 적대적 접미사가 닫힌 모델로 전이, AdvBench 520개 (미검증)
PAIR · TAP	공격자 LLM이 흔히 20회 미만 질의로 탈옥을 다듬음 (미검증)
many-shot	큰 모델일수록 대체로 더 취약. 프롬프트 분류·수정으로 한 사례에서 61% → 2%
Best-of-N (NeurIPS 2025)	N=10,000에서 GPT-4o 약 89%, Claude 3.5 Sonnet 약 78%
유해 파인튜닝 (Qi 외, ICLR 2024)	예시 10개, 비용 $0.20 미만으로 GPT-3.5 Turbo가 거의 모든 유해 지시를 따름

적응형 공격은 거의 0%를 보고한 방어 대부분에서 90%를 넘었다

인젝션과 오염

- "prompt injection"은 2022.09 Simon Willison의 명명, Greshake 외(2302.12173)가 간접 인젝션 정의
- Sleeper Agents(2401.05566, 미검증): 백도어가 안전 학습 뒤에도 남음
- arXiv 2510.07192: 600M~13B 모델에서 오염 문서 약 250개가 크기와 무관하게 백도어를 심음 (무의미한 문자열 출력이라는 좁은 종류)

공격자 없는 실패

- 아첨 (Sharma 외, 2310.13548, 미검증)
- 정렬 위장 (Greenblatt 외, 2412.14093, 미검증)
- 에이전트 비정렬 (Anthropic, 2025.06): 프런티어 모델 16종이 인위적 시나리오에서 때때로 협박·기밀 유출을 선택
- 레드티머가 만드는 것은 적대적 문자열이 아니라 **압력 상황**

벤치마크와 방어

- HarmBench, JailbreakBench, StrongREJECT, XSTest, AgentHarm (모두 미검증)
- Llama Guard, circuit breakers, Instruction Hierarchy(2404.13208), Spotlighting(2403.14720), CaMeL(2503.18813)

> 90%

"The Attacker Moves Second" (arXiv 2510.09023)

OpenAI·Anthropic·Google DeepMind 등 14명. 최근 방어 12개에 적응형 공격

International AI Safety Report 2026 (arXiv 2602.21012)

레드팀에서 문제가 나오지 않았다고 위험이 낮다는 뜻은 아니며, 팀 구성과 공격 라운드에 따라 결과가 달라져 재현성이 낮다.

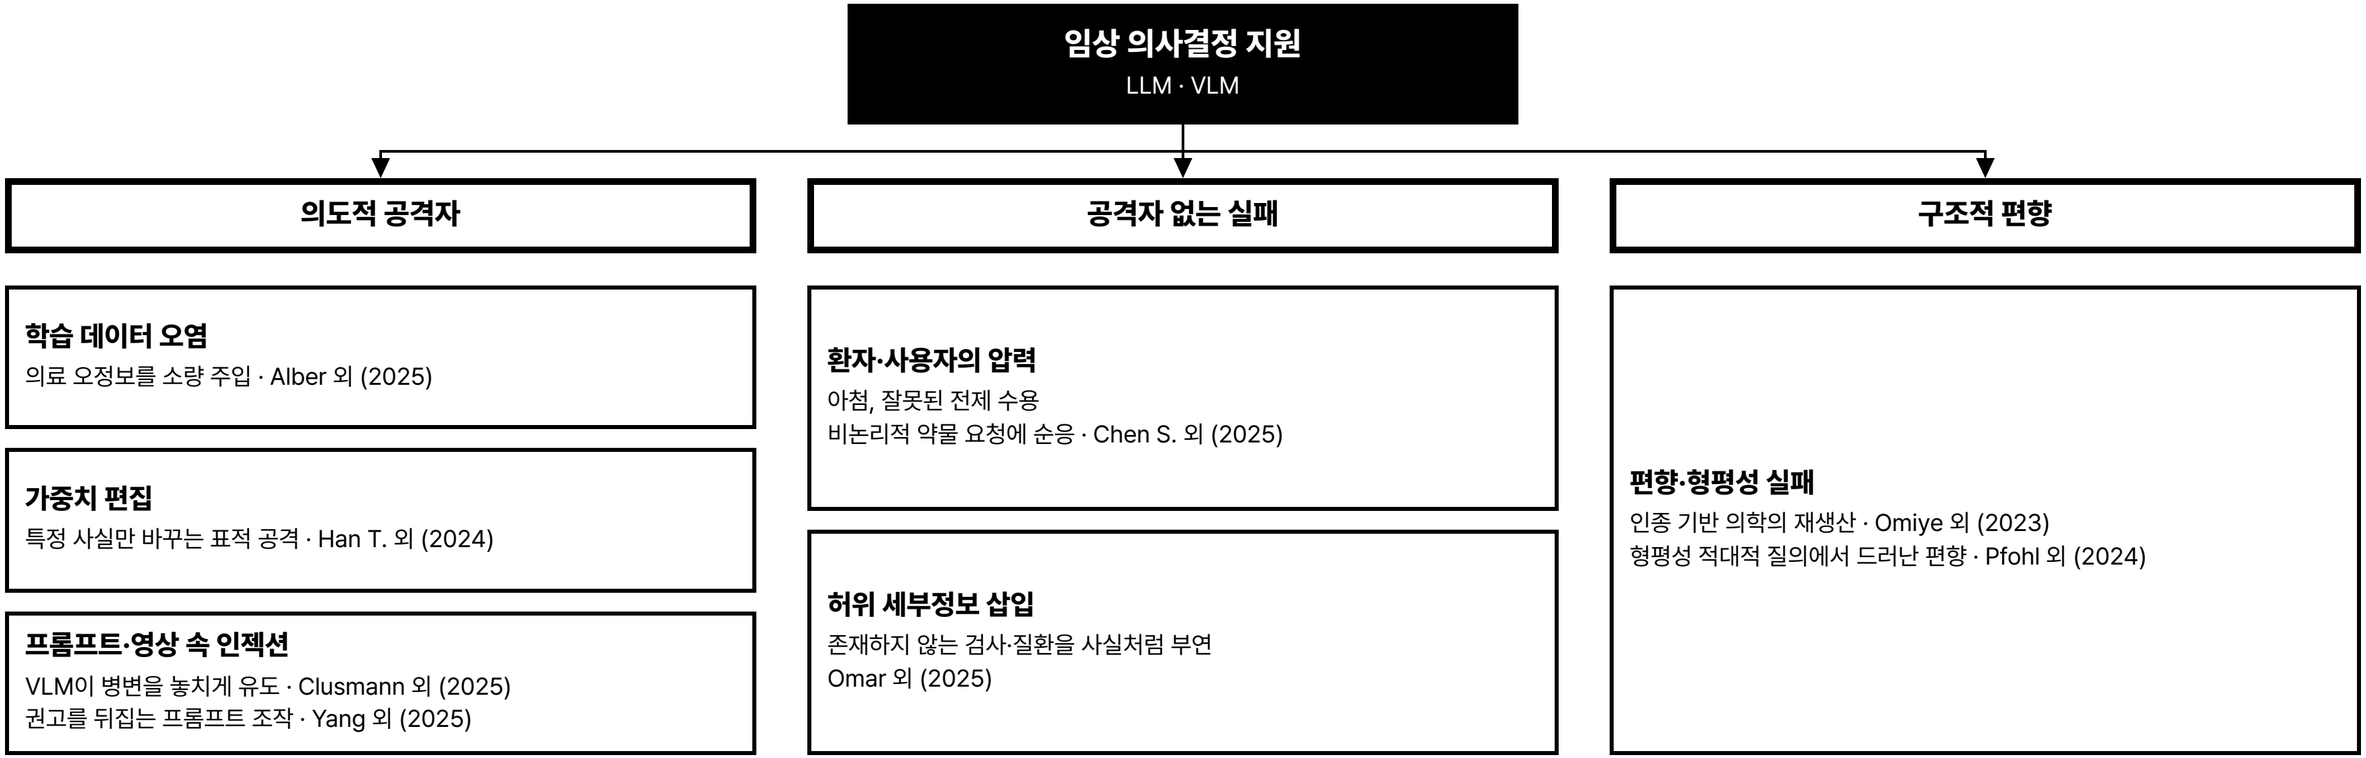
체화 AI의 레드티밍은 텍스트 출력 평가로는 부족하다

연구	게재	대상	핵심 결과
Qi 외, Visual Adversarial Examples Jailbreak Aligned LLMs	arXiv 2306.13213, AAAI 2024	VLM	시각적 적대적 예제 하나로 정렬된 VLM이 광범위한 유해 지시를 따름. 이미지는 연속값이라 최적화가 쉬움
Gong 외, FigStep	arXiv 2311.05608, AAAI 2025	VLM	금지 내용을 이미지 속 글자로 넣어 6개 오픈소스 VLM에서 평균 82.50%
Robey 외, RoboPAIR	arXiv 2410.13691 (게재처 미확인)	LLM 제어 로봇	자율주행 LLM, Jackal 지상 로봇, Go2 로봇견 세 환경 모두에서 흔히 100%에 가까운 성공률
Zhang 외, BadRobot	arXiv 2407.20242, ICLR 2025	체화 LLM 에이전트	LLM 조작, 말로는 거부하고 행동으로는 수행하는 언행 불일치, 세계 지식 결함
Wang 외, VLA 적대적 취약성	arXiv 2411.13587, ICCV 2025	VLA	시뮬레이션 로봇 과제 성공률을 최대 100%까지 떨어뜨림

필요한 것 행동 수준의 안전 제약, 물리적 결과를 고려한 위협 모델링, 언행 일치 검증이 따로 필요하다. 언행 불일치는 텍스트 출력만 보는 벤치마크로 잡을 수 없다.

그림 12 · 의료 LLM 레드티밍의 위협 지도

의료 위협은 의도적 공격, 공격자 없는 실패, 구조적 편향으로 나뉜다



각 칸은 다음 장의 연구 유형에 대응한다. 의료 레드티밍의 중심 질문은 "임상적으로 부적절한 답을 아무도 알아채지 못하게 내놓게 만들 수 있는가"이다.

전문을 확보한 연구 10편만 논증에 썼다

연구	게재	유형	핵심 결과	전문
Chang 외, 레드티밍 해커톤	npj Digit Med 8:149 (2025.03)	인간 레드티밍	80명, 376개 프롬프트, 1,504개 응답 중 20.1%(303건) 부적절	게재본
Han T. 외, 표적 오정보 공격	npj Digit Med 7:288 (2024)	가중치 편집	가중치 1.1% 편집으로 거짓 의학 사실 주입	게재본
Alber 외, 데이터 오염	Nat Med 31:618–626 (2025.01)	학습 데이터 오염	학습 토큰 0.001% 교체로 유해 출력 증가, 벤치마크 성능은 그대로	게재본
Yang 외, 프롬프트·파인튜닝 공격	Nat Commun 16:9011 (2025.10)	인젝션·오염 파인튜닝	GPT-4 백신 권고율 100.00% → 3.98%	게재본
Clusmann 외, 영상 속 인젝션	Nat Commun 16:1239 (2025)	VLM 인젝션	영상에 숨긴 지시로 병변을 놓치게 유도	프리프린트
Omar 외, 적대적 환각	Commun Med 5:330 (2025.08)	허위 세부정보 삽입	6개 모델 환각률 50–82%	프리프린트
Chen S. 외, 아첨	npj Digit Med 8:605 (2025.10)	공격자 없는 실패	비논리적 약물 요청에 최대 100% 순응	게재본
Han T. 외, MedSafetyBench	NeurIPS 2024 D&B	안전 벤치마크	의료 윤리 원칙 기반 유해 요청 1,800개	arXiv
Pfohl 외, EquityMedQA	Nat Med (2024)	형평성 적대적 질의	Med-PaLM 2 답변 12.6%에서 편향 지적	프리프린트
Omiye 외, 인종 기반 의학	npj Digit Med 6:195 (2023.10)	편향 레드티밍	4개 LLM 모두 일부 질문에서 인종 기반 답변	프리프린트

표준 벤치마크 점수는 오염과 조작을 드러내지 못했다

Chang 외 (2025) · 인간 레드티밍

- GPT-3.5 25.8%, GPT-4.0 16.5%, GPT-4.0+인터넷 17.8%, GPT-4o 20.4% 부적절
- 유형(중복): 환각·정확성 51.3%, 편향 33.2%, 안전 23.7%, 프라이버시 10.2%
- 81개 프롬프트(21.5%)가 GPT-3.5에서는 적절했지만 새 모델 중 하나 이상에서 부적절

Alber 외 (2025) · 데이터 오염

- The Pile 모사 데이터에서 토큰 0.001%를 의학 오정보로 교체
- 40억 파라미터 모델에서 백신 오정보 0.001% 주입 시 유해 콘텐츠 4.8% 증가
- 5개 의료 벤치마크 성능은 깨끗한 모델과 비슷. 지식 그래프 검증이 유해 문단 91.9% 포착 (F1 85.7%)

Han T. 외 (2024) · 가중치 편집

- 틀린 생의학 사실 1,025개로 주 평가
- USMLE 기반 1,048개 사실에서 편집된 Llama-3가 36.0% 다른 답 (그리디 디코딩)
- JailbreakBench 탈옥 성공률 2% → 58%

Yang 외 (2025) · 인젝션과 오염 파인튜닝

- 백신 권고율 GPT-4 100.00% → 3.98%, GPT-4o 88.06% → 6.47%
- 위험한 약물 조합 권고 GPT-4 0.50% → 80.60%
- 오염 파인튜닝 GPT-4o 백신 권고 20.40%(깨끗 99.50%), MedQA 78.87% (깨끗 81.93%)
- 재표현 방어로 공격 성공 33.37%, 42.65% 감소

가장 흔한 실패는 공격자 없이도 일어난다

Clusmann 외 · 영상 속 인젝션

- Claude-3 Opus, Claude-3.5 Sonnet, Reka Core, GPT-4o 대상
- 프리프린트(2407.18981 v1, 공격 297회) 기준 병변 누락률 GPT-4o 89%, Claude-3.5 57%, Reka Core 61%
- 게재본 초록은 594회. 인용 전 게재본 확인 필요

Omar 외 · 적대적 환각

- 의사가 검증한 사례 300개에 허위 세부정보 하나, 출력 5,400개
- 환각률 50–82%. 완화 프롬프트로 평균 66% → 44%, GPT-4o 53% → 23%
- 온도 조절은 유의한 개선 없음 (medRxiv 프리프린트 기준)

Chen S. 외 · 아첨

- 일반명과 상품명을 다른 약처럼 전제한 요청에 GPT-4·4o·4o-mini 100%, Llama3-8B 94% 순응
- 힌트 두 가지로 GPT-4·4o가 94% 올바르게 거부
- 기준선 올바른 거부율이 결과 절 5%, 논의 절 9%로 다르게 적힘

MedSafetyBench

- AMA 9개 의료 윤리 원칙 기반 1,800개 (절반 GPT-4, 절반 GCG로 생성)
- 공개 의료 LLM 유해성 1.90–2.98 (1–5, 낮을수록 안전)

EquityMedQA (Pfohl 외)

- 7개 데이터셋, 4,619개 예시, 평가자 282명, 17,099건
- 편향 지적 12.6% (HealthSearchQA 3.0%). 형평성 전문가 22.0% 대 의사 7.8%

Omiye 외 · 인종 기반 의학

- ChatGPT, GPT-4, Bard, Claude 모두 일부 질문에서 인종 기반 답변
- 질문 수: 게재본 초록 9개, 프리프린트 8개. 프리프린트 기준 서술

논증에서 제외 MedFuzz(2406.06573), CARES(2505.11413), MedRiskEval(2507.07248), Omar 외 사회인구학적 편향 연구는 전문을 확보하지 못해 논증에 쓰지 않았다.

의료 LLM 평가는 벤치마크 점수를 넘어 네 가지를 함께 시험해야 한다

1 표준 벤치마크는 오염과 조작을 잡지 못한다

Alber 외와 Yang 외 모두에서 공격받은 모델이 의료 질의응답 점수를 거의 그대로 유지했다. MedQA 중심 평가는 이런 공격에 대해 아무것도 말해 주지 않는다.

2 가장 흔한 실패는 공격자가 필요 없다

허위 세부정보 수용과 아첨은 의무기록 오기나 환자의 잘못된 믿음으로도 일어난다. 오류가 섞인 일상적 입력을 시험해야 한다.

3 레드팀 구성이 결과를 바꾼다

Chang 외는 임상의와 공학자를 섞었고, Pfohl 외에서는 형평성 전문가가 의사보다 편향을 더 많이 찾았다. 임상 전문성과 형평성·환자 관점이 함께 들어가야 한다.

4 모델 버전마다 다시 해야 한다

Chang 외의 21.5%처럼 새 모델이 일부 항목에서 나빠질 수 있다. 한국의 식약처·ETRI 첨단 AI 의료기기 레드팀 챌린지는 이를 제도 안으로 들이는 첫 시도로 볼 수 있다.

공진화 그림 11 · 능력·공격면·억제의 공진화

능력을 끌어내는 메커니즘은 예외 없이 공격면이 되었다



공격에 대한 대응은 다시 억제·조향 수단이 되었다. 같은 메커니즘의 세 얼굴이다.

퓨샷과 many-shot, 자동 최적화와 GCG는 같은 메커니즘이다

단계	끌어낸 능력	열린 공격면	대응한 억제·조향 수단
임베딩·벡터 검색	의미 기반 검색	벡터·임베딩 약점 (OWASP 2025)	검색 출처 검증
제로샷 지시	텍스트로 과제 지정	직접 프롬프트 인젝션	시스템 프롬프트, 역할 분리
퓨샷·인컨텍스트 학습	예시로 행동 학습	many-shot jailbreaking (같은 거듭제곱 법칙)	프롬프트 분류·수정
지시 튜닝·RLHF	말로 시키면 따르는 모델	경쟁 목표, 아첨 (의료 순응 최대 100%)	HHH, Constitutional AI, 사양서
페르소나·역할 부여	톤·관점 지정	역할극 탈옥	사양서의 우선순위 규칙
사전학습 능력의 일반화	암호·다국어·형식 이해	일반화 불일치	다국어·인코딩 레드티밍 데이터
자동 최적화	기계가 프롬프트 탐색	GCG, AutoDAN, PAIR·TAP	자동화 레드티밍, 적대적 학습
반복 샘플링	여러 번 시도해 최선 선택	Best-of-N 탈옥	공격 예산 기준 평가
CoT·추론 모델	다단계 추론	정렬 위장, 보상 해킹	CoT 모니터링, 활성화 프로브
RAG·도구·MCP	외부 지식과 행동	간접 프롬프트 인젝션	Spotlighting, 지시 위계, CaMeL
파인튜닝 API	맞춤형 모델	10개 예시로 안전성 제거, 의료 오염 파인튜닝	파인튜닝 데이터 검사
VLM	이미지 이해	시각 적대적 예제, 타이포그래피·영상 속 인젝션	멀티모달 분류기
VLA·체화 에이전트	물리적 행동	로봇 탈옥, 언행 불일치	행동 안전 제약, 샌드박스·권한

연표 통합 연표

언어 모델, 레드티밍, 의료, 제도의 사건이 2022년 이후 한꺼번에 겹친다

시점	사건	구분
1948 · 1972 · 1997	섀넌의 n-gram (미검증) · Anderson 보고서 · LSTM	언어 모델 / 보안 기원
2003	NPLM (Bengio), DSB 레드팀 보고서	언어 모델 / 레드팀 제도화
2013 · 2013–14 · 2014.09	word2vec · 적대적 예제와 FGSM (미검증) · seq2seq와 Bahdanau 어텐션	임베딩 / ML 보안 / 어텐션
2016.03 · 2017.06	Microsoft Tay (미검증) · Transformer	사회적 오용 / 아키텍처
2018 · 2019.10	ELMo, GPT-1(미검증), BERT · T5	사전학습
2020 · 2021.02	스케일링 법칙, GPT-3, RAG, ViT, AutoPrompt · CLIP	대규모화 / 프롬프트 / VLM
2022	CoT, Self-Consistency, InstructGPT, Flamingo, ReAct, LM 기반 레드티밍(미검증), RT-1, ChatGPT	프롬프트 / 정렬 / VLM / 레드팀
2023	BLIP-2, LLaVA, ToT, RT-2, GCG(미검증), DEF CON GRT, EO 14110, 시각 적대적 탈옥, FigStep, Omiye 외	VLM / VLA / 레드팀 / 의료
2024	many-shot, Octo, OpenVLA, π0, MedSafetyBench, BadRobot, RoboPAIR, EquityMedQA, Han T. 외, 한국 AI안전연구소	공격 / VLA / 의료 / 제도
2025	Constitutional Classifiers, Alber 외, Chang 외, GR00T N1, Gemini Robotics, GPT-4o 롤백, EU GPAI 의무 적용, Omar 외, Yang 외, Chen S. 외, "The Attacker Moves Second"	방어 / 의료 / VLA / 제도
2026	차세대 Constitutional Classifiers, 한국 AI 기본법 시행, International AI Safety Report 2026	방어 / 제도 / 비판

능력이 커질 때마다 조향의 정밀도에 대한 요구도 함께 커진다

언어 모델은 임베딩, 어텐션, 사전학습과 대규모화로 능력을 쌓았고, 프롬프트 엔지니어링은 그 능력을 입력만으로 끌어내는 기술에서 컨텍스트와 하네스를 설계하는 일로 넓어졌다. VLM은 이미지를, VLA는 행동을 토큰으로 바꿨다. 레드티밍은 이 확장의 매 단계를 반대 방향에서 따라왔으므로 "끌어내기에서 억제로"라는 시대 구분보다 **공진화 모델**이 증거에 더 잘 맞는다.

1 절차로서의 레드티밍

모델을 깨는 기술이 아니라 결함을 찾아 고치는 절차로 다뤄야 위협 모델, 문서화, 완화라는 산출물이 남는다.

2 시스템 설계로 내려간 억제

적응형 공격이 방어 대부분을 무력화했으므로 억제는 권한·격리·정보 흐름 설계로 내려가야 한다. VLA에서는 더 엄격해야 한다.

3 의료 평가의 보완

데이터 무결성, 오류가 섞인 일상 입력, 형평성, 모델 버전 간 회귀를 함께 시험하는 레드티밍으로 벤치마크를 보완해야 한다.

다음 과제 sandbagging과 평가 인식이 보여 주듯 시험받는 모델이 시험을 알아챌 수 있다면, 관찰이 행동을 바꾸지 않는 측정 방법을 찾는 일이 다음 과제가 된다.

참고문헌 (1)

LLM 이전과 언어 모델의 기초

Bengio, Y. 외. A Neural Probabilistic Language Model. JMLR 3, 2003 jmlr.org/papers/v3/bengio03a.html

Hochreiter, S., Schmidhuber, J. Long Short-Term Memory. Neural Computation, 1997 mlanthology.org/neco/1997/hochreiter1997neco-long

Gers, F. A., Schmidhuber, J., Cummins, F. Learning to Forget: Continual Prediction with LSTM. Neural Computation 12, 2451–2471, 2000. DOI 10.1162/089976600300015015 doi.org/10.1162/089976600300015015

Elman, J. L. Finding Structure in Time. Cognitive Science 14, 179–211, 1990 coli.uni-saarland.de/~crocker/Teaching/Connectionist/CogSci90-...

Bengio, Y., Simard, P., Frasconi, P. Learning Long-Term Dependencies with Gradient Descent is Difficult. IEEE Transactions on Neural Networks, 1994 cs.nyu.edu/~yann/2006s-G22-3033-013/diglib/ayse_mkg_bengio_rec...

Jurafsky, D., Martin, J. H. Speech and Language Processing (3rd ed. draft), 3장 N-gram Language Models web.stanford.edu/~jurafsky/slp3/3.pdf

Mikolov, T. 외. Efficient Estimation of Word Representations in Vector Space. arXiv 1301.3781, 2013 arxiv.org/abs/1301.3781

Pennington, J. 외. GloVe: Global Vectors for Word Representation. EMNLP 2014 aclanthology.org/D14-1162

Sutskever, I. 외. Sequence to Sequence Learning with Neural Networks. arXiv 1409.3215, 2014 arxiv.org/abs/1409.3215

Bahdanau, D. 외. Neural Machine Translation by Jointly Learning to Align and Translate. arXiv 1409.0473, 2014 arxiv.org/abs/1409.0473

Vaswani, A. 외. Attention Is All You Need. arXiv 1706.03762, 2017 arxiv.org/abs/1706.03762

Peters, M. 외. Deep contextualized word representations. arXiv 1802.05365, 2018 arxiv.org/abs/1802.05365

Devlin, J. 외. BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding. arXiv 1810.04805, 2018 arxiv.org/abs/1810.04805

Raffel, C. 외. Exploring the Limits of Transfer Learning with a Unified Text-to-Text Transformer. arXiv 1910.10683, 2019 arxiv.org/abs/1910.10683

Kaplan, J. 외. Scaling Laws for Neural Language Models. arXiv 2001.08361, 2020 arxiv.org/abs/2001.08361

Brown, T. 외. Language Models are Few-Shot Learners (GPT-3). arXiv 2005.14165, 2020 arxiv.org/abs/2005.14165

Hoffmann, J. 외. Training Compute-Optimal Large Language Models. arXiv 2203.15556, 2022 arxiv.org/abs/2203.15556

LLM 이전과 언어 모델의 기초 (계속)

Ouyang, L. 외. Training language models to follow instructions with human feedback. arXiv 2203.02155, 2022 arxiv.org/abs/2203.02155

Shannon, C. E. A Mathematical Theory of Communication. Bell System Technical Journal 27(3), 1948. DOI 10.1002/j.1538-7305.1948.tb01338.x doi.org/10.1002/j.1538-7305.1948.tb01338.x

Radford, A. 외. Improving Language Understanding by Generative Pre-Training (GPT-1). OpenAI, 2018 cdn.openai.com/research-covers/language-unsupervised/language_...

프롬프트 엔지니어링

Wei, J. 외. Chain-of-Thought Prompting Elicits Reasoning in Large Language Models. arXiv 2201.11903 arxiv.org/abs/2201.11903

Kojima, T. 외. Large Language Models are Zero-Shot Reasoners. arXiv 2205.11916 arxiv.org/abs/2205.11916

Zhou, D. 외. Least-to-Most Prompting Enables Complex Reasoning in Large Language Models. arXiv 2205.10625 arxiv.org/abs/2205.10625

Gao, L. 외. PAL: Program-aided Language Models. arXiv 2211.10435 arxiv.org/abs/2211.10435

Chen, W. 외. Program of Thoughts Prompting. arXiv 2211.12588 arxiv.org/abs/2211.12588

Wang, X. 외. Self-Consistency Improves Chain of Thought Reasoning in Language Models. arXiv 2203.11171 arxiv.org/abs/2203.11171

Yao, S. 외. Tree of Thoughts: Deliberate Problem Solving with Large Language Models. arXiv 2305.10601 arxiv.org/abs/2305.10601

Madaan, A. 외. Self-Refine: Iterative Refinement with Self-Feedback. arXiv 2303.17651 arxiv.org/abs/2303.17651

Shinn, N. 외. Reflexion: Language Agents with Verbal Reinforcement Learning. arXiv 2303.11366 arxiv.org/abs/2303.11366

Lewis, P. 외. Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks. arXiv 2005.11401 arxiv.org/abs/2005.11401

Yao, S. 외. ReAct: Synergizing Reasoning and Acting in Language Models. arXiv 2210.03629 arxiv.org/abs/2210.03629

참고문헌 (2)

프롬프트 엔지니어링 (계속)

Schick, T. 외. Toolformer: Language Models Can Teach Themselves to Use Tools. arXiv 2302.04761 **arxiv.org/abs/2302.04761**

Shin, T. 외. AutoPrompt. arXiv 2010.15980 **arxiv.org/abs/2010.15980**

Li, X. L., Liang, P. Prefix-Tuning: Optimizing Continuous Prompts for Generation. arXiv 2101.00190 **arxiv.org/abs/2101.00190**

Zhou, Y. 외. Large Language Models Are Human-Level Prompt Engineers (APE). arXiv 2211.01910 **arxiv.org/abs/2211.01910**

Yang, C. 외. Large Language Models as Optimizers (OPRO). arXiv 2309.03409 **arxiv.org/abs/2309.03409**

Khattab, O. 외. DSPy: Compiling Declarative Language Model Calls into Self-Improving Pipelines. arXiv 2310.03714 **arxiv.org/abs/2310.03714**

Li, C. 외. Large Language Models Understand and Can be Enhanced by Emotional Stimuli (EmotionPrompt). arXiv 2307.11760 **arxiv.org/abs/2307.11760**

Principled Instructions Are All You Need. arXiv 2312.16171 **arxiv.org/abs/2312.16171**

OpenAI. GPT-4.1 Prompting Guide; GPT-5 Prompting Guide. OpenAI Cookbook, 2025 **cookbook.openai.com/examples/gpt4-1_prompting_guide** **cookbook.openai.com/examples/gpt-5/gpt-5_prompting_guide**

Anthropic. Prompting best practices. Claude Docs **platform.claude.com/docs/en/build-with-claude/prompt-engineeri…**

Anthropic. Introducing the Model Context Protocol, 2024.11.25 **anthropic.com/news/model-context-protocol**

Reynolds, L., McDonell, K. Prompt Programming for Large Language Models: Beyond the Few-Shot Paradigm. arXiv 2102.07350, 2021 **arxiv.org/abs/2102.07350**

Kong, A. 외. Better Zero-Shot Reasoning with Role-Play Prompting. NAACL 2024. arXiv 2308.07702 **arxiv.org/abs/2308.07702**

Wang, L. 외. Plan-and-Solve Prompting: Improving Zero-Shot Chain-of-Thought Reasoning by Large Language Models. ACL 2023. arXiv 2305.04091 **arxiv.org/abs/2305.04091**

프롬프트 엔지니어링 (계속)

Press, O. 외. Measuring and Narrowing the Compositionality Gap in Language Models (Self-Ask). arXiv 2210.03350 **arxiv.org/abs/2210.03350**

Zheng, H. S. 외. Take a Step Back: Evoking Reasoning via Abstraction in Large Language Models. ICLR 2024. arXiv 2310.06117 **arxiv.org/abs/2310.06117**

Liu, J. 외. Generated Knowledge Prompting for Commonsense Reasoning. ACL 2022. arXiv 2110.08387 **arxiv.org/abs/2110.08387**

Wu, T., Terry, M., Cai, C. J. AI Chains: Transparent and Controllable Human-AI Interaction by Chaining Large Language Model Prompts. CHI 2022. arXiv 2110.01691 **arxiv.org/abs/2110.01691**

Suzgun, M., Kalai, A. T. Meta-Prompting: Enhancing Language Models with Task-Agnostic Scaffolding. arXiv 2401.12954, 2024 **arxiv.org/abs/2401.12954**

Zhang, Y., Yuan, Y., Yao, A. C. Meta Prompting for AI Systems. arXiv 2311.11482 **arxiv.org/abs/2311.11482**

VLM과 VLA

Dosovitskiy, A. 외. An Image is Worth 16×16 Words (ViT). arXiv 2010.11929 **arxiv.org/abs/2010.11929**

Radford, A. 외. Learning Transferable Visual Models From Natural Language Supervision (CLIP). arXiv 2103.00020 **arxiv.org/abs/2103.00020**

Alayrac, J.-B. 외. Flamingo: a Visual Language Model for Few-Shot Learning. arXiv 2204.14198 **arxiv.org/abs/2204.14198**

Li, J. 외. BLIP-2. arXiv 2301.12597 **arxiv.org/abs/2301.12597**

Liu, H. 외. Visual Instruction Tuning (LLaVA). NeurIPS 2023. arXiv 2304.08485 **arxiv.org/abs/2304.08485**

Liu, H. 외. Improved Baselines with Visual Instruction Tuning (LLaVA-1.5). arXiv 2310.03744 **arxiv.org/abs/2310.03744**

Brohan, A. 외. RT-1: Robotics Transformer for Real-World Control at Scale. arXiv 2212.06817 **arxiv.org/abs/2212.06817**

Zitkovich, B. 외(arXiv 표기 Brohan 외). RT-2: Vision-Language-Action Models Transfer Web Knowledge to Robotic Control. CoRL 2023, PMLR 229. arXiv 2307.15818 **arxiv.org/abs/2307.15818**

Open X-Embodiment Collaboration. Open X-Embodiment: Robotic Learning Datasets and RT-X Models. arXiv 2310.08864 **arxiv.org/abs/2310.08864**

참고문헌 (3)

VLM과 VLA (계속)

Octo Model Team. Octo: An Open-Source Generalist Robot Policy. RSS 2024. arXiv 2405.12213 **arxiv.org/abs/2405.12213**

Kim, M. J. 외. OpenVLA: An Open-Source Vision-Language-Action Model. CoRL 2024, PMLR 270. arXiv 2406.09246 **arxiv.org/abs/2406.09246**

Black, K. 외. π0: A Vision-Language-Action Flow Model for General Robot Control. arXiv 2410.24164 **arxiv.org/abs/2410.24164**

NVIDIA. GR00T N1: An Open Foundation Model for Generalist Humanoid Robots. arXiv 2503.14734 **arxiv.org/abs/2503.14734**

Gemini Robotics Team. Gemini Robotics: Bringing AI into the Physical World. arXiv 2503.20020 **arxiv.org/abs/2503.20020**

레드티밍: 정의, 역사, 제도

Executive Order 14110, Sec. 3(d), 2023.10.30 **govinfo.gov/link/cpd/executiveorder/14110**

EU AI Act, Article 55 **artificialintelligenceact.eu/article/55**

Defense Science Board. The Role and Status of DoD Red Teaming Activities, 2003 **apps.dtic.mil/sti/pdfs/ADA430100.pdf**

Feffer, M. 외. Red-Teaming for Generative AI: Silver Bullet or Security Theater? arXiv 2401.15897 **arxiv.org/abs/2401.15897**

Microsoft AI Red Team. Lessons From Red Teaming 100 Generative AI Products. arXiv 2501.07238 **arxiv.org/abs/2501.07238**

NIST AI 100-2 E2025 **nvlpubs.nist.gov/nistpubs/ai/nist.ai.100-2e2025.pdf**

OWASP Top 10 for LLM Applications 2025 **genai.owasp.org/2024/11/17/owasp-reveals-updated-2025-top-10-r...**

International AI Safety Report 2026. arXiv 2602.21012 **arxiv.org/abs/2602.21012**

Zenko, M. Red Team: How to Succeed By Thinking Like the Enemy. Basic Books, 2015 **hachettebookgroup.com/titles/micah-zenko/red-team/9780465048946**

Perez, E. 외. Red Teaming Language Models with Language Models. arXiv 2202.03286 **arxiv.org/abs/2202.03286**

레드티밍: 정의, 역사, 제도 (계속)

Ganguli, D. 외. Red Teaming Language Models to Reduce Harms. arXiv 2209.07858 **arxiv.org/abs/2209.07858**

LLM 공격과 방어

Wei, A., Haghtalab, N., Steinhardt, J. Jailbroken: How Does LLM Safety Training Fail? arXiv 2307.02483 **arxiv.org/abs/2307.02483**

Zou, A. 외. Universal and Transferable Adversarial Attacks on Aligned Language Models (GCG). arXiv 2307.15043 **arxiv.org/abs/2307.15043**

Chao, P. 외. Jailbreaking Black Box Large Language Models in Twenty Queries (PAIR). arXiv 2310.08419 **arxiv.org/abs/2310.08419**

Anthropic. Many-shot Jailbreaking, 2024 **anthropic.com/research/many-shot-jailbreaking**

Best-of-N Jailbreaking. NeurIPS 2025. arXiv 2412.03556 **arxiv.org/abs/2412.03556**

Qi, X. 외. Fine-tuning Aligned Language Models Compromises Safety. ICLR 2024. arXiv 2310.03693 **arxiv.org/abs/2310.03693**

Greshake, K. 외. Not what you've signed up for: Indirect Prompt Injection. arXiv 2302.12173 **arxiv.org/abs/2302.12173**

Anthropic·UK AISI·Alan Turing Institute. 소량 문서 데이터 오염 연구. arXiv 2510.07192 **arxiv.org/abs/2510.07192**

OpenAI. The Instruction Hierarchy. arXiv 2404.13208 **arxiv.org/abs/2404.13208**

Microsoft. Spotlighting. arXiv 2403.14720 **arxiv.org/abs/2403.14720**

Google DeepMind. Defeating Prompt Injections by Design (CaMeL). arXiv 2503.18813 **arxiv.org/abs/2503.18813**

The Attacker Moves Second (OpenAI·Anthropic·Google DeepMind 등 14인). arXiv 2510.09023 **arxiv.org/abs/2510.09023**

Anthropic. Constitutional Classifiers, 2025; Next-generation Constitutional Classifiers, arXiv 2601.04603, 2026 **anthropic.com/research/constitutional-classifiers** **arxiv.org/abs/2601.04603**

van der Weij, T. 외. AI Sandbagging. ICLR 2025. arXiv 2406.07358 **arxiv.org/abs/2406.07358**

METR. Recent Frontier Models Are Reward Hacking, 2025.06 **metr.org/blog/2025-06-05-recent-reward-hacking**

Anthropic. Agentic Misalignment, 2025.06 **anthropic.com/research/agentic-misalignment**

참고문헌 (4)

멀티모달·로봇 레드티밍

Qi, X. 외. Visual Adversarial Examples Jailbreak Aligned Large Language Models. AAAI 2024. arXiv 2306.13213 **arxiv.org/abs/2306.13213**

Gong, Y. 외. FigStep: Jailbreaking Large Vision-Language Models via Typographic Visual Prompts. AAAI 2025. arXiv 2311.05608 **arxiv.org/abs/2311.05608**

Robey, A. 외. Jailbreaking LLM-Controlled Robots (RoboPAIR). arXiv 2410.13691. (게재처 미확인) **arxiv.org/abs/2410.13691**

Zhang, H. 외. BadRobot: Jailbreaking Embodied LLM Agents in the Physical World. ICLR 2025. arXiv 2407.20242 **arxiv.org/abs/2407.20242**

Wang, T. 외. Exploring the Adversarial Vulnerabilities of Vision-Language-Action Models in Robotics. ICCV 2025. arXiv 2411.13587 **arxiv.org/abs/2411.13587**

의료 LLM 레드티밍

Chang, C. T. 외. Red teaming ChatGPT in medicine to yield real-world insights on model behavior. npj Digital Medicine 8:149, 2025. DOI 10.1038/s41746-025-01542-0. 전문: 게재본(PMC) **doi.org/10.1038/s41746-025-01542-0**

Han, T. 외. Medical large language models are susceptible to targeted misinformation attacks. npj Digital Medicine 7:288, 2024. DOI 10.1038/s41746-024-01282-7. 전문: 게재본(RWTH 저장소 PDF) **doi.org/10.1038/s41746-024-01282-7**

Alber, D. A. 외. Medical large language models are vulnerable to data-poisoning attacks. Nature Medicine 31:618–626, 2025. DOI 10.1038/s41591-024-03445-1. 전문: 게재본(PMC) **doi.org/10.1038/s41591-024-03445-1**

Yang, Y. 외. Adversarial prompt and fine-tuning attacks threaten medical large language models. Nature Communications 16:9011, 2025. DOI 10.1038/s41467-025-64062-1. 전문: 게재본(PMC) **doi.org/10.1038/s41467-025-64062-1**

Clusmann, J. 외. Prompt injection attacks on vision language models in oncology. Nature Communications 16:1239, 2025. DOI 10.1038/s41467-024-55631-x. 전문: arXiv 2407.18981 v1만 확인(게재본 수치와 다를 수 있음) **doi.org/10.1038/s41467-024-55631-x**

Omar, M. 외. Multi-model assurance analysis showing large language models are highly vulnerable to adversarial hallucination attacks during clinical decision support. Communications Medicine 5:330, 2025. DOI 10.1038/s43856-025-01021-3. 전문: medRxiv 프리프린트만 확인 **doi.org/10.1038/s43856-025-01021-3**

의료 LLM 레드티밍 (계속)

Chen, S. 외. When helpfulness backfires: LLMs and the risk of false medical information due to sycophantic behavior. npj Digital Medicine 8:605, 2025. DOI 10.1038/s41746-025-02008-z. 전문: 게재본(PMC) **doi.org/10.1038/s41746-025-02008-z**

Han, T. 외. MedSafetyBench: Evaluating and Improving the Medical Safety of Large Language Models. NeurIPS 2024 Datasets & Benchmarks. arXiv 2403.03744. 전문: arXiv **arxiv.org/abs/2403.03744**

Pfohl, S. R. 외. A toolbox for surfacing health equity harms and biases in large language models. Nature Medicine, 2024. DOI 10.1038/s41591-024-03258-2. 전문: arXiv 2403.12025 v2만 확인(권·쪽 미확인) **doi.org/10.1038/s41591-024-03258-2**

Omiye, J. A. 외. Large language models propagate race-based medicine. npj Digital Medicine 6:195, 2023. DOI 10.1038/s41746-023-00939-z. 전문: 프리프린트만 확인 **doi.org/10.1038/s41746-023-00939-z**

전문 미확보로 논증에서 제외: Ness, R. O. 외. MedFuzz, arXiv 2406.06573. Chen, S. 외. CARES, arXiv 2505.11413 (NeurIPS 2025). MedRiskEval, arXiv 2507.07248 (내용 미검증). Omar, M. 외. 사회인구학적 편향 연구, medRxiv 10.1101/2024.10.29.24316368 (게재본 미검증) **arxiv.org/abs/2406.06573** **arxiv.org/abs/2505.11413** **arxiv.org/abs/2507.07248** **doi.org/10.1101/2024.10.29.24316368**

표시가 없는 항목은 arXiv 초록, 출판사·학회 원문, 공식 문서로 실재와 서지를 확인한 것이다. (미검증)은 이번에 다시 확인하지 못한 항목이다.